

金融随机微分方程的数值模拟

从欧拉法到嵌套网格验证：PDE 数值解课程项目汇报

姓名：_____ 学号：_____

数值偏微分方程课程

2026 年 9 月


这份汇报希望解决什么问题？

面向的听众

只学过常微分方程欧拉法和基础概率论；不要求随机微积分或金融知识。

- ① 如何把随机微分方程放到时间网格上计算？
- ② Monte Carlo 为什么能估计期望？误差条怎样得到？
- ③ Euler-Maruyama 与 Milstein 的差别在哪里？
- ④ “强收敛”与“弱收敛”分别回答什么问题？
- ⑤ 没有解析解时，怎样用嵌套网格构造可信的数值参考？
- ⑥ 如何读懂本项目的图、表和最终结论？

整项工作的主线



数值分析的核心

不是只运行一次程序，而是说明：离散格式是什么、误差怎样缩小、统计噪声有多大、结论能否复现。

它与数值 PDE 课程有什么关系？

对一维扩散过程

$$dS_t = a(S_t) dt + b(S_t) dW_t,$$

定义条件期望

$$u(t, s) = \mathbb{E}[\varphi(S_T) \mid S_t = s].$$

在适当条件下, u 满足后向 Kolmogorov 方程

$$u_t + a(s)u_s + \frac{1}{2}b(s)^2u_{ss} = 0, \quad u(T, s) = \varphi(s).$$

两条求解路线

- ▶ PDE 路线：在 (t, s) 网络上离散偏导数；
- ▶ 本项目路线：在时间上离散随机轨道，再用 Monte Carlo 求平均。

本项目不要求实现 PDE 求解器，但仍在研究离散、收敛、稳定计算和误差量化。

报告中的两个模型与各自任务

	模型一：GBM 基准	模型二：非仿射耦合模型
作用	有解析解，可检查程序和理论阶	更接近无解析解的真实数值任务
方法	精确采样、EM、Milstein	对数变量上的 EM
主要指标	强误差、弱误差、分布矩	嵌套参考、强差、非线性弱量
参考答案	同一布朗路径上的解析终值	更细网格上的数值解
关键困难	分清路径误差与期望误差	参考解本身也有离散误差

先用可验证模型建立信任，再把方法迁移到不能精确求解的模型。

汇报结构

1. 从欧拉法到随机时间步进
2. 模型一：用解析解验证数值方法
3. 模型二：无解析解时的嵌套网格验证
4. 如何评价结果与组织代码

1. 从欧拉法到随机时间步进

回顾：常微分方程的显式欧拉法

对 ODE

$$\frac{dy}{dt} = f(y), \quad y(0) = y_0,$$

建立均匀网格

$$0 = t_0 < t_1 < \cdots < t_N = T, \quad h = \frac{T}{N}.$$

在一个小区间上假设斜率近似不变：

$$y(t_{n+1}) - y(t_n) \approx f(y_n)h, \quad \boxed{y_{n+1} = y_n + f(y_n)h}.$$

理解重点

连续变化被替换为许多小步； h 越小，局部近似通常越好，但计算量增加。

随机微分方程只多了一种“随机步长”

一般 SDE 写成

$$dZ_t = a(Z_t) dt + b(Z_t) dW_t.$$

- ▶ $a(Z_t) dt$: 漂移项, 类似 ODE 的确定性变化;
- ▶ $b(Z_t) dW_t$: 扩散项, 表示随机扰动;
- ▶ W_t : 布朗运动, 不可微, 因此不能直接套普通 Taylor 展开。

在一步 $[t_n, t_{n+1}]$ 上:

$$Z_{t_{n+1}} - Z_{t_n} = \int_{t_n}^{t_{n+1}} a(Z_t) dt + \int_{t_n}^{t_{n+1}} b(Z_t) dW_t.$$

把两个系数冻结在左端点, 就得到最基本的随机欧拉法。

布朗增量：程序中真正生成的随机数

布朗运动的增量满足

$$\Delta W_n = W_{t_{n+1}} - W_{t_n} \sim \mathcal{N}(0, h), \quad \Delta W_n = \sqrt{h} Z_n, \text{quad} Z_n \sim \mathcal{N}(0, 1).$$

均值

$$\mathbb{E}[\Delta W_n] = 0.$$

正负扰动平均抵消。

尺度

$$\text{SD}(\Delta W_n) = \sqrt{h}.$$

随机项是 $O(\sqrt{h})$ ，比 $O(h)$ 更大。

最常见的实现错误

写成 hZ_n 会让随机扰动缩小得过快，得到完全错误的极限模型。

Euler-Maruyama：随机版显式欧拉法

冻结一步内的系数：

$$\int_{t_n}^{t_{n+1}} a(Z_t) dt \approx a(Z_n)h, \quad \int_{t_n}^{t_{n+1}} b(Z_t) dW_t \approx b(Z_n)\Delta W_n.$$

得到 Euler-Maruyama (EM) 格式

$$Z_{n+1} = Z_n + a(Z_n)h + b(Z_n)\Delta W_n.$$

- ▶ 与显式欧拉一样：只使用第 n 步已知值；
- ▶ 新增的输入是 $\Delta W_n = \sqrt{h}Z_n$ ；
- ▶ 每组随机增量生成一条近似路径；
- ▶ 重复许多路径，才可以估计期望或误差。

Monte Carlo: 从一次随机结果到一个期望

若目标是 $\mathbb{E}[X]$ ，独立生成 M 个样本 $X^{(1)}, \dots, X^{(M)}$:

$$\hat{m}_M = \frac{1}{M} \sum_{i=1}^M X^{(i)}.$$

大数定律说明 $\hat{m}_M \rightarrow \mathbb{E}[X]$ 。中心极限定理给出误差尺度

$$\text{SE}(\hat{m}_M) \approx \frac{s_X}{\sqrt{M}}.$$

近似 95% 置信区间为

$$\hat{m}_M \pm 1.96 \frac{s_X}{\sqrt{M}}.$$

代价规律

要把统计误差缩小一半，样本量需扩大约 4 倍。只减小 h 而不增加 M ，误差曲线可能被抽样噪声淹没。

总误差由两部分组成

用离散格式估计期望时，可以把误差概念性地拆成

$$\underbrace{\hat{Q}_{h,M} - Q}_{\text{总误差}} = \underbrace{(\mathbb{E}[Q_h] - Q)}_{\text{时间离散偏差}} + \underbrace{(\hat{Q}_{h,M} - \mathbb{E}[Q_h])}_{\text{Monte Carlo 噪声}}.$$

常见数量级是

$$|\text{离散偏差}| \approx Ch^p, \quad |\text{统计误差}| \approx C_M M^{-1/2}.$$

实验设计原则

若想测时间收敛阶 p ，必须让样本噪声小于正在测量的离散误差；否则最细网格只会显示噪声平台。

为什么随机 Taylor 展开会多出修正项？

对光滑函数 f ，Itô 公式可类比为随机版链式法则：

$$df(Z_t) = f'(Z_t) dZ_t + \frac{1}{2} f''(Z_t) b(Z_t)^2 dt.$$

普通链式法则没有最后一项。它出现是因为

$(\Delta W)^2$ 的典型大小是 h ,

因而二阶随机项不能像 ODE 中那样忽略。

对本项目够用的记忆方式

$\Delta W = O(\sqrt{h})$ ，所以 $(\Delta W)^2 = O(h)$ ；随机展开中的某些二阶项与漂移项同阶。

Milstein: 保留一个关键的随机二阶项

对一维 SDE

$$dZ = a(Z) dt + b(Z) dW,$$

Milstein 格式为

$$Z_{n+1} = Z_n + a(Z_n)h + b(Z_n)\Delta W_n + \frac{1}{2}b(Z_n)b'(Z_n)((\Delta W_n)^2 - h).$$

- ▶ 前三项正是 EM;
- ▶ 新项的均值为零, 因为 $\mathbb{E}[(\Delta W)^2] = h$;
- ▶ 它修正路径级局部误差, 常把一维问题的强阶从 $1/2$ 提高到 1 ;
- ▶ 多维噪声下会出现更复杂的迭代积分, 本项目不需要实现。

同一路径耦合：公平比较的关键

若粗网格一步包含 q 个细步，定义

$$\Delta W_k^{\text{coarse}} = \sum_{j=1}^q \Delta W_{kq+j}^{\text{fine}}.$$

因为方差相加，粗增量自动满足

$$\Delta W_k^{\text{coarse}} \sim \mathcal{N}(0, qh_{\text{fine}}).$$

正确比较

粗、细解由同一条布朗路径驱动；差值主要反映离散误差。

错误比较

分别生成独立噪声；差值主要反映两条不同随机路径。

强误差与弱误差：两个不同问题

强误差：路径是否接近？

$$e_{\text{strong}}(h) = \mathbb{E}|Z_T^h - Z_T|.$$

必须让两者共享同一条布朗路径。适合路径模拟、轨迹相关问题。

弱误差：统计量是否接近？

$$e_{\text{weak}}(h) = \left| \mathbb{E}\varphi(Z_T^h) - \mathbb{E}\varphi(Z_T) \right|.$$

只比较某个观测量的期望。适合均值、方差、payoff 等。

不能互相替代

一个方法可以逐路径不够准确，却仍把某个期望算得很准；而某个特殊期望甚至可能对所有步长都恰好精确。

收敛阶如何从图上读出？

若误差满足

$$e(h) \approx Ch^p,$$

取对数得到直线

$$\log e \approx \log C + p \log h.$$

因此 log-log 图中的拟合斜率就是阶 p 。

收敛阶	h 减半后误差约乘	连续减半两次
$p = 1/2$	$2^{-1/2} \approx 0.707$	约减半
$p = 1$	$2^{-1} = 0.5$	约变为四分之一

拟合斜率只是数据证据；还要同时检查误差条、拟合区间和参考解误差。

2. 模型一：用解析解验证数值方法

GBM：一个可精确求解的乘性噪声模型

模型写成

$$\boxed{dS_t = \mu S_t dt + \sigma S_t dW_t}, \quad S_0 = 100, \mu = 0.05, \sigma = 0.30, T = 1.$$

- ▶ 漂移与扩散都与当前值 S_t 成正比；
- ▶ 金融上可理解为价格模型，但本项目只把它当作数值测试方程；
- ▶ 它有解析解，因此可以精确测量数值误差；
- ▶ 真解始终为正，是检查离散格式的一个额外指标。

为什么先做它？

若程序在有标准答案的模型上不能复现理论阶，就不应直接相信无解析解模型的结果。

GBM 的解析解从哪里来?

对 $f(S) = \log S$ 使用 Itô 公式:

$$d \log S_t = \frac{1}{S_t} dS_t - \frac{1}{2} \frac{1}{S_t^2} (\sigma S_t)^2 dt = \left(\mu - \frac{1}{2} \sigma^2 \right) dt + \sigma dW_t.$$

积分并取指数:

$$S_t = S_0 \exp \left[\left(\mu - \frac{1}{2} \sigma^2 \right) t + \sigma W_t \right].$$

Itô 修正的意义

指数中的 $-\sigma^2/2$ 不是金融假设, 而是随机链式法则产生的二阶修正。

解析矩：除了路径，还能检查分布

由对数正态分布可得

$$\mathbb{E}[S_T] = S_0 e^{\mu T}, \quad \text{Var}(S_T) = S_0^2 e^{2\mu T} (e^{\sigma^2 T} - 1).$$

本项目参数下

$$\mathbb{E}[S_T] = 105.1271, \quad \text{Var}(S_T) = 1040.7868.$$

精确采样实验给出

$$\widehat{\mathbb{E}}[S_T] = 105.1987, \quad \widehat{\text{Var}}(S_T) = 1045.0120.$$

偏差与 Monte Carlo 抽样波动相容，说明随机数生成和精确终值公式工作正常。

GBM 的三个一步更新公式

令 $\Delta W_n \sim \mathcal{N}(0, h)$ 。

精确一步： $S_{n+1} = S_n \exp\left[\left(\mu - \frac{1}{2}\sigma^2\right)h + \sigma\Delta W_n\right],$

EM： $S_{n+1} = S_n (1 + \mu h + \sigma\Delta W_n),$

Milstein： $S_{n+1} = S_n \left[1 + \mu h + \sigma\Delta W_n + \frac{1}{2}\sigma^2((\Delta W_n)^2 - h)\right].$

公平实验

三个更新必须复用相同的 ΔW_n ；这样路径差来自格式，而不是随机输入不同。

GBM 实现：核心循环其实很短

```
h = T / N
dW = np.sqrt(h) * rng.standard_normal((M, N))

S_em = np.full(M, S0)
S_mil = np.full(M, S0)
for n in range(N):
    dw = dW[:, n]
    S_em *= 1.0 + mu*h + sigma*dw
    S_mil *= (1.0 + mu*h + sigma*dw
              + 0.5*sigma**2*(dw**2 - h))

W_T = dW.sum(axis=1)
S_exact = S0*np.exp((mu - 0.5*sigma**2)*T + sigma*W_T)
```

- ▶ 数组长度 M ：同一时间同时推进 M 条路径；
- ▶ `codeW_T` 用相同增量求和，确保强误差是耦合比较。


实验协议：先固定规则，再看结果

- ▶ 时间区间： $T = 1$ ，网格数 $N = 2^k$ ；步长 $h = T/N$ ；
- ▶ 每个 h 使用相同数量的路径，并固定随机种子；
- ▶ 强误差： $\hat{e} = M^{-1} \sum_i |S_{T,i}^h - S_{T,i}^{\text{exact}}|$ ；
- ▶ 强误差标准误：对逐路径绝对误差计算 $s/\sqrt{M}$ ；
- ▶ 弱误差：优先使用可解析计算的 $|\mathbb{E}[S_T^h] - \mathbb{E}[S_T]|$ ；
- ▶ 在预先说明的渐近网格区间做 log-log 线性拟合。

为什么固定随机种子？

它不让结果“更正确”，但能让同一命令得到同一组伪随机样本，便于复现和核对报告数字。

GBM 强收敛结果



拟合斜率：EM 0.500；Milstein 0.991。

怎样解释上一张强误差图？


方法	$N = 64$	$N = 1024$
EM	0.66641	0.16658
Milstein	0.02391	0.00153

- ▶ N 增大 16 倍，即 h 缩小 16 倍；
- ▶ EM 误差约缩小 4 倍： $16^{1/2} = 4$ ；
- ▶ Milstein 误差约缩小 15.6 倍，接近 16^1 。


结论

数据与理论强阶相符：EM 为 $1/2$ ，Milstein 为 1。这也是代码实现正确的主要验证之一。

Individual Challenge: 改进前后应怎样呈现?



改进前：只有误差曲线，无法判断斜率估计的稳定性。



Fit window: $N=64,128,256,512,1024$. Bands use 20 independent seeds $\times$ 20,000 paths; within-seed grids are Brownian-coupled.

改进后：增加重复实验误差条、理论参考斜率与拟合斜率。

把一句“图像看起来符合理论”改成可以量化、检查和复现的证据。

弱误差可以直接解析计算

EM 的条件均值满足

$$\mathbb{E}[S_{n+1}^{\text{EM}} | S_n^{\text{EM}}] = S_n^{\text{EM}}(1 + \mu h).$$

递推后

$$\mathbb{E}[S_N^{\text{EM}}] = S_0(1 + \mu h)^N, \quad N = T/h.$$


Milstein 修正项均值为零, 因此其均值与 EM 完全相同:

$$\mathbb{E}[(\Delta W)^2 - h] = 0.$$

对比真均值 $S_0 e^{\mu T}$, 得到无 Monte Carlo 噪声的弱误差

$$e_{\text{weak}}(h) = \left| S_0(1 + \mu h)^{T/h} - S_0 e^{\mu T} \right| = O(h).$$

GBM 弱收敛结果：为什么两条线重合？



EM 拟合斜率 0.999, Milstein 拟合斜率 1.000; 二者对均值这一观测量具有同一个解析偏差。



Milstein 路径更准，为什么均值阶没有提高？

- ▶ Milstein 的额外项改善了每条路径与真路径的匹配，因此强阶提高；
- ▶ 但该额外项期望为零，没有改变一步条件均值；
- ▶ 所以对 $\varphi(S) = S$ ，EM 与 Milstein 的弱误差相同；
- ▶ 换成其他非线性 φ 时，结论可能不同。

方法的“阶”必须带上指标

“Milstein 比 EM 高阶”在本项目中准确地说是：对这个一维模型，Milstein 的强阶更高；不能据此断言每个弱观测量都更高阶。

分布检查：误差阶之外的第二道防线



直方图应与解析对数正态密度一致；经验均值、方差还应落在合理抽样误差内。

正值性检查：明确报告负值频率

真解由指数构成，所以 $S_t > 0$ 。离散格式未必自动保持这一性质。

终值生成方式	负终值数 / 总路径数	经验频率
精确更新	0/160000	0.000%
Euler-Maruyama	0/160000	0.000%
Milstein	0/160000	0.000%

该结果的边界

这是本次参数和网格下的经验终值频率，不能证明 EM 对所有步长或所有参数都保持正值。

GBM 阶段得到了什么？

- ① 验证了布朗增量使用 $\sqrt{h}$ 缩放，并正确复用了同一路径；
- ② 复现 EM 强阶约 1/2、Milstein 强阶约 1；
- ③ 解析解释了二者对终值均值都有一阶弱误差；
- ④ 用解析矩、分布图与正值频率补充检查；
- ⑤ 学会了把 log-log 斜率与具体误差缩减倍数对应起来。

下一步

去掉解析解这根“拐杖”，在非仿射模型中用更细数值网格充当参考答案。

3. 模型二：无解析解时的嵌套网格验证

非仿射模型：状态依赖的随机波动

令 $S_t = e^{X_t}$ ，模型为

$$dX_t = \left(\mu - \frac{1}{2}g(Y_t)^2 \right) dt + g(Y_t) dW_t^{(1)},$$

$$dY_t = \kappa(\theta - Y_t) dt + \xi \sqrt{1 + Y_t^2} dW_t^{(2)},$$

$$g(y) = 0.1 + \frac{0.4}{1 + e^{-y}}, \quad \text{Corr}(dW^{(1)}, dW^{(2)}) = \rho.$$

- ▶ Y_t 是辅助状态； $g(Y_t)$ 决定 X_t 的瞬时噪声强度；
- ▶ g 和 $\sqrt{1 + Y^2}$ 都不是仿射函数，因此称为非仿射；
- ▶ 没有可直接使用的终值解析解。

只需掌握这些参数含义

参数	数值分析中的作用	本项目值
S_0, Y_0	初始条件	100, 0
μ	X 的平均增长部分	0.05
κ, θ	Y 拉回中心的速度与中心	2, -0.2
ξ	Y 的噪声尺度	0.6
ρ	两个随机驱动的相关系数	-0.7
T	终止时间	1

对金融背景的最低要求

只需把 S 当作需要模拟的正状态变量，把 Y 当作会改变噪声强度的第二个状态变量。

怎样生成相关的两个布朗增量？

先生成独立标准正态变量 Z_1, Z_2 ，再令

$$\Delta W_1 = \sqrt{h}Z_1, \quad \Delta W_2 = \sqrt{h} \left(\rho Z_1 + \sqrt{1 - \rho^2} Z_2 \right).$$

则

$$\text{Var}(\Delta W_1) = \text{Var}(\Delta W_2) = h, \quad \text{Corr}(\Delta W_1, \Delta W_2) = \rho.$$

必须做的数值诊断

程序生成后直接计算样本方差和样本相关系数；本实验得到相关系数 -0.699675 ，与目标 -0.7 一致。

为什么在 $X = \log S$ 上离散?

直接更新 S 可能因一个大的负随机增量得到负数。改为更新 X 后再指数变换:

$$S_n = e^{X_n} > 0$$

在计算机产生有限浮点数的前提下自动为正。

这不是额外金融技巧

它是变量变换后的数值格式选择：用解析结构保证状态约束，类似 PDE 中通过变量或通量形式改善离散性质。

非仿射模型的同步 EM 更新

用旧值 Y_n 同时更新两个分量：

$$X_{n+1} = X_n + \left(\mu - \frac{1}{2}g(Y_n)^2 \right) h + g(Y_n)\Delta W_{1,n},$$

$$Y_{n+1} = Y_n + \kappa(\theta - Y_n)h + \xi\sqrt{1 + Y_n^2}\Delta W_{2,n},$$

$$S_{n+1} = e^{X_{n+1}}.$$

同步的含义

X_{n+1} 和 Y_{n+1} 都只能使用同一个旧状态 Y_n 。若先覆盖 Y_n 再更新 X ，实际实现的就不是上述格式。

实现细节：保存旧状态并稳定计算 sigmoid

```
def g(y):  
    # stable sigmoid to avoid exp overflow  
    return 0.1 + 0.4 * expit(y)  
  
for n in range(N):  
    y_old = y.copy()  
    gy = g(y_old)  
    x += (mu - 0.5*gy**2)*h + gy*dW1[:, n]  
    y += kappa*(theta - y_old)*h \  
        + xi*np.sqrt(1.0 + y_old**2)*dW2[:, n]  
  
assert np.isfinite(x).all() and np.isfinite(y).all()  
s = np.exp(x)
```

除了最终图，还应记录：是否出现 NaN/Inf、相关系数、增量方差和负价格数。

一个重要结构：离散均值恰好正确

给定 $\mathcal{F}_n$ 后, $g(Y_n)$ 是已知量。由正态变量的指数矩

$$\mathbb{E}[e^{a\Delta W}] = e^{a^2 h/2},$$

有

$$\mathbb{E}[S_{n+1} \mid \mathcal{F}_n] = S_n e^{(\mu - \frac{1}{2}g_n^2)h} \mathbb{E}[e^{g_n \Delta W_{1,n}}] = S_n e^{\mu h}.$$

所以

$$\mathbb{E}[S_N] = S_0 e^{\mu T} \quad \text{对任意步长 } h \text{ 都成立.}$$

后果

用 $\varphi(S) = S$ 测弱误差会得到理论零偏差, 无法检验格式是否正确逼近终值分布。

为什么选择 call payoff 作为非平凡弱观测量？

选取

$$\varphi(S) = (S - K)^+ = \max(S - K, 0), \quad K = 100.$$

- ▶ 它是非线性函数， $\mathbb{E}[\varphi(S)]$ 不能只由 $\mathbb{E}[S]$ 决定；
- ▶ 即使两个离散解均值相同，只要分布的形状或尾部不同，payoff 期望就会不同；
- ▶ 在 $S = K$ 处有折点，不是光滑测试函数，因此有限样本下收敛更难测；
- ▶ 这里使用它的原因是数值辨别力，理解这一点不需要金融定价知识。

核心逻辑

线性均值被格式结构“自动答对”后，必须换一个会感知分布差异的观测量。

没有解析解时：用嵌套细网格作参考

在同一组最细布朗增量上同时构造：

$$S_T^N \quad \text{和} \quad S_T^{N_{\text{ref}}}, \quad N_{\text{ref}} \gg N.$$

粗增量由细增量求和，定义强差

$$\hat{D}_N = \frac{1}{M} \sum_{i=1}^M \left| S_{T,i}^N - S_{T,i}^{N_{\text{ref}}} \right|.$$

对弱观测量使用配对差

$$\hat{B}_N = \frac{1}{M} \sum_{i=1}^M \left[\varphi(S_{T,i}^N) - \varphi(S_{T,i}^{N_{\text{ref}}}) \right].$$

准确措辞


它们是相对于数值参考解的差，不是已知真误差；所以必须做参考网格敏感性检查。

嵌套实验参数

项目	设置
粗网格	$N = 8, 16, 32, 64, 128, 256$
主要参考网格	$N_{\text{ref}} = 8192$
敏感性参考网格	2048, 4096, 8192
路径数	$M = 100000$
随机耦合	所有网格聚合同一最细增量
强量	$\mathbb{E} S_T^N - S_T^{N_{\text{ref}}} $
弱量	均值差与 call payoff 配对差

拟合强阶时只用 $N = 8, 16, 32, 64$ ，避免最细粗网格过度接近有限参考网格而弯曲。

非仿射模型：强差结果



相对 $N_{\text{ref}} = 8192$ 的拟合斜率为 0.491，与 EM 的典型强阶 $1/2$ 相容。

怎样证明这个斜率不是参考网格偶然造成？

固定拟合粗网格 $N = 8, 16, 32, 64$ ，改变参考网格：

N_{ref}	拟合斜率	对最粗层的解释
2048	0.496	参考误差较大，但斜率稳定 与更细参考接近 主报告采用
4096	0.493	
8192	0.491	

可支持的结论

三个参考层给出一致的约 $1/2$ 斜率，因此有较稳健的数值证据支持 EM 型强收敛行为。

参考解自身误差怎样显现？

比较相邻参考层的终值差：


$$\mathbb{E}|S_T^{2048} - S_T^{4096}| \approx 0.05679, \quad \mathbb{E}|S_T^{4096} - S_T^{8192}| \approx 0.04016.$$

比值为

$$\frac{0.04016}{0.05679} \approx 0.707 \approx 2^{-1/2}.$$

- ▶ 参考层本身也呈现半阶缩减；
- ▶ 这说明 8192 仍不是“真解”；
- ▶ 但对较粗的 $N = 8$ 到 64，它足够细，可观察到稳定渐近斜率。

非仿射模型：弱差与置信区间



粗层 payoff 差可辨认；细层误差条跨过零，Monte Carlo 噪声已与离散差同量级。

为什么这里不能报告可靠弱阶？

- ▶ $N = 8, 16, 32$ 时，payoff 配对差的置信区间不含零；
- ▶ $N = 64, 128, 256$ 时，置信区间包含零；
- ▶ 最细层上，误差符号和大小受抽样噪声明显影响；
- ▶ 对这些点做 log-log 回归会把噪声当成收敛规律；
- ▶ payoff 有折点，弱误差常数和渐近区间也可能更难辨认。

正确结论

本实验显示弱偏差随网格细化而减小，但在现有样本预算下不足以估计可信的弱收敛阶。这是诚实的数值结论，不是格式被证明失败。

样本量实验：增加 M 是否解决问题？

固定 $N = 64$ 、 $N_{\text{ref}} = 8192$ ，只改变路径数：

M	payoff 配对差	标准误	95% 置信区间
10,000	0.009045	0.005149	$[-0.001048, 0.019137]$
40,000	0.004942	0.002592	$[-0.000139, 0.010022]$
100,000	0.001722	0.001633	$[-0.001479, 0.004923]$

- ▶ 标准误大体按 $M^{-1/2}$ 缩小；
- ▶ 三个区间仍都跨过零；
- ▶ 说明该层的真实偏差很小，需要更大预算或方差缩减才适合估阶。

均值诊断：精确结构也能检查代码

理论上对任意步长

$$\mathbb{E}[S_T^N] = 100e^{0.05} = 105.1271.$$

最细模拟得到

$$\hat{\mathbb{E}}[S_T] = 105.08796, \quad 95\% \text{ CI } [104.89962, 105.27629].$$

理论值落在区间内。对应 payoff 估计为

$$14.53804, \quad 95\% \text{ CI } [14.40515, 14.67093].$$

两种角色

均值用于检查实现；payoff 用于观察非平凡分布偏差。不要强迫同一个统计量承担两项任务。

数值诊断清单

检查项	本项目观察
布朗增量方差	与目标最细步长 $1/8192 \approx 1.221 \times 10^{-4}$ 一致
两驱动相关系数	-0.699675 ，目标为 -0.7
有限性	所有报告路径的 X, Y, S 均为有限数
正值性	$S = e^X$ ，模拟价格保持正值
精确均值结构	理论值落在经验 95% 区间内
参考层敏感性	三个参考网格给出相近强斜率

一张漂亮的收敛图不能替代这些基本检查。

4. 如何评价结果与组织代码

哪些结论是任务真正要求的？

内容	应做	本项目证据
GBM 强收敛	比较 EM、Milstein 理论阶	0.500 与 0.991
GBM 弱行为	选定观测量并解释	均值偏差解析一阶
分布/正值检查	定量报告	矩、直方图、负值频率
非仿射强验证	嵌套网格与敏感性	稳定约半阶
非仿射弱验证	置信区间与谨慎结论	趋势可见，阶不可可靠估计
复现性	命令、种子、环境、Git	代码与输出可追溯

“测出的弱阶”不是必须成功等于某个漂亮数字；必须做的是采用合理实验并报告证据的限度。


代码结构应当对应数学结构

- ❶ **参数层**：初值、系数、 T 、网格、路径数、随机种子；
- ❷ **随机增量层**：生成最细独立正态数，构造相关增量；
- ❸ **求解器层**：EM、Milstein、对数 EM；
- ❹ **耦合层**：细增量求和得到各个粗网格输入；
- ❺ **统计层**：误差均值、标准误、置信区间、回归斜率；
- ❻ **输出层**：表格、图、机器可读数据和运行元数据。

好处

若图中某个点异常，可以沿着“数据—统计量—路径—随机增量—参数”逐层定位，而不是在一个大脚本里猜测。

复现一个报告数字的最小闭环



如果脚本输出与报告不一致，应修正报告或查清版本，而不是只保留更好看的数字。

最容易犯的八个错误

- ❶ 把 ΔW 写成 hZ ，遗漏 $\sqrt{h}$ ；
- ❷ 强误差比较时使用独立随机路径；
- ❸ 把样本方差当作估计均值的标准误；
- ❹ 只减小 h ，却不检查 Monte Carlo 噪声平台；
- ❺ 更新 Y 后才用新 Y 更新 X ，破坏同步 EM 格式；
- ❻ 把有限细网格称为“精确解”；
- ❼ 对跨零且符号不稳的弱偏差强行做 log-log 拟合；
- ❽ 只报告斜率，不报告拟合区间、误差条和诊断。

如何读一张合格的收敛图？

按以下顺序提问：

- ① 横轴是 h 、 N 还是计算成本？方向是否反转？
- ② 纵轴具体是什么误差？是真误差、参考差还是绝对偏差？
- ③ 粗细解是否共享同一随机输入？
- ④ 误差条表示标准差、标准误还是置信区间？
- ⑤ 斜率在哪些点上拟合？为何选择这些点？
- ⑥ 最细点是否进入 Monte Carlo 噪声平台或参考误差平台？
- ⑦ 改变样本量或参考层后，结论是否稳定？

一条实用规则

先确认纵轴“测的是什么”，再看线是否直，最后才读拟合斜率。

项目的主要结论

- ① 在 GBM 基准上，EM 与 Milstein 的强阶分别约为 $1/2$ 和 1 ，与理论一致；
- ② 对终值均值，二者共享同一个一阶弱偏差，说明强阶提高不等于每个弱量都提高；
- ③ 在非仿射模型上，嵌套参考实验稳定显示约 $1/2$ 的强收敛行为；
- ④ 非仿射离散均值对所有步长都精确，所以非线性 payoff 才能检验分布偏差；
- ⑤ 现有路径数只能支持“弱偏差趋于减小”，不足以给出可信弱阶；
- ⑥ 置信区间、参考层敏感性和运行诊断与拟合斜率同样重要。

如果继续改进，优先做什么？

- ① 对 payoff 弱误差使用更多配对样本，或加入控制变量降低方差；
- ② 在固定计算预算下平衡 h 与 M ，避免某一种误差远小于另一种；
- ③ 进一步加细参考网格，量化参考解带来的系统偏差；
- ④ 报告回归斜率的置信区间，而不只给点估计；
- ⑤ 若课程希望比较 PDE 与 Monte Carlo，可在二维简化模型上增加有限差分解作交叉验证。

本科作业的合理边界

这些是后续方向。当前报告最重要的是把已有方法、证据和局限解释清楚，而不是继续堆叠更复杂技术。

谢谢！

Questions?

从欧拉法出发，我们只增加了三样东西：**正态增量、重复抽样、误差的统计量化。**

5. 备用推导与答疑页

备用：GBM 均值偏差为何是一阶？

令 $N = T/h$ 。使用展开

$$\log(1 + \mu h) = \mu h - \frac{1}{2}\mu^2 h^2 + O(h^3),$$

则

$$\begin{aligned}(1 + \mu h)^{T/h} &= \exp\left[\frac{T}{h} \log(1 + \mu h)\right] \\ &= \exp\left[\mu T - \frac{1}{2}\mu^2 Th + O(h^2)\right] \\ &= e^{\mu T} \left(1 - \frac{1}{2}\mu^2 Th + O(h^2)\right).\end{aligned}$$

因而

$$S_0(1 + \mu h)^{T/h} - S_0 e^{\mu T} = O(h).$$

备用：为什么配对差能降低弱误差噪声？

两种估计方式：

$$\text{独立： } \hat{\mathbb{E}}[\varphi(S^N)] - \hat{\mathbb{E}}[\varphi(S^{\text{ref}})],$$

$$\text{配对： } \frac{1}{M} \sum_i [\varphi(S_i^N) - \varphi(S_i^{\text{ref}})].$$

对配对差，单个样本的方差是

$$\text{Var}(A - B) = \text{Var}(A) + \text{Var}(B) - 2 \text{Cov}(A, B).$$

共享布朗路径使 A, B 高度正相关，协方差项显著降低差值方差。

直观理解

同一次随机冲击把粗、细解一起推高或推低；相减时共同波动抵消，剩下的主要是离散差。

备用：标准误与样本量

若配对差样本为 $D_1, \dots, D_M$ ，则

$$\bar{D} = \frac{1}{M} \sum_i D_i, \quad s_D^2 = \frac{1}{M-1} \sum_i (D_i - \bar{D})^2, \quad \text{SE}(\bar{D}) = \frac{s_D}{\sqrt{M}}.$$

若希望标准误从 ε_1 降到 ε_2 ，粗略需要

$$M_2 \approx M_1 \left(\frac{\varepsilon_1}{\varepsilon_2} \right)^2.$$

例如将标准误缩小到原来的 $1/5$ ，路径数需约增加到 25 倍。

备用：术语速查

术语	本项目中的意思
漂移 drift	每单位时间的平均确定性变化
扩散 diffusion	随机扰动的幅度
布朗增量	均值 0、方差 h 的正态随机量
路径 path	一整串 $Z_0, Z_1, \dots, Z_N$
观测量 observable	对终值取的函数 $\varphi(Z_T)$
强收敛	同一路径上的数值解接近真解
弱收敛	某个观测量的期望接近真值
嵌套网格	粗增量由同一批细增量求和得到
数值参考解	很细网格解，用于近似未知真解



课程 Problem Pack, Direction 4: Financial SDEs, pp. 6–7.



D. J. Higham,
An Algorithmic Introduction to Numerical Simulation of Stochastic Differential Equations,
SIAM Review, 43(3), 2001.



P. E. Kloeden and E. Platen,
Numerical Solution of Stochastic Differential Equations,
Springer, 1992.

项目脚本: `gbm.py`、`nonaffine.py`; 本科版报告: `undergraduate_revision/`。