

金融随机微分方程的数值模拟

第四题：GBM 基准与非仿射波动率

课程作业报告（中文译本）

2026 年 9 月

摘要

本文比较几何布朗运动 (GBM) 的精确模拟、Euler–Maruyama (EM) 方法和 Milstein 方法，并研究一个需要数值参考解的非仿射随机波动率模型。所有离散方法都通过聚合布朗增量使用共同随机路径。对于 GBM，终值强收敛的测量阶数为 0.500 (EM) 和 0.991 (Milstein)，与理论上的 $1/2$ 阶和 1 阶一致。我们使用配对差、独立拟合的控制变量和解析的离散均值公式，将弱均值偏差与蒙特卡洛抽样不确定性分开；终值分布则与精确的对数正态分布比较。对于非仿射模型，我们对数价格和波动率因子都使用 EM，因此模拟价格保持为正。给定拟合窗口上的经验强阶为 0.491。我们用置信区间和三层嵌套参考网格报告收益偏差；当偏差无法由抽样误差中分辨出来时，不强行指定弱收敛阶。实验说明：精确基准可以验证方法，而数值网格之间的一致只能通过参考网格加密来评估。

目录

1 引言与理论背景	2
2 蒙特卡洛方法	3
3 模型与实验方案	4
4 GBM 数值结果	6
5 非仿真模型的数值结果	10
6 参考网格加密与验证	13
7 讨论与结论	14
A Python 实现与复现	15

可复现性：随报告提供完整 Python 源码、随机种子、数值表格、图形和运行记录。报告中的置信区间是逐点蒙特卡洛区间。

1 引言与理论背景

题目给出的 SDE 方向要求研究强收敛、弱收敛、抽样不确定性以及嵌套网格验证；这些内容取代了确定性 ODE 中的稳定域和自适应步长分析 [1]。GBM 有精确的路径基准，而题目规定的非仿射模型必须把时间离散作为模型求解的一部分。本文的目标是说明实验真正验证了什么，而不是根据看起来合理的样本路径猜测精度。

1.1 GBM 及其精确转移

当 $S_0 > 0$ 时，Itô 随机微分方程和对数变换为

$$dS_t = \mu S_t dt + \sigma S_t dW_t, \quad (1)$$

$$dX_t = (\mu - \frac{1}{2}\sigma^2) dt + \sigma dW_t, \quad X_t = \log S_t. \quad (2)$$

Itô 修正项非常重要：漏掉 $-\sigma^2/2$ 会改变价格均值。积分得到

$$S_t = S_0 \exp\{(\mu - \frac{1}{2}\sigma^2)t + \sigma W_t\}. \quad (3)$$

因此 S_T 服从对数正态分布，且

$$m = \mathbb{E}[S_T] = S_0 e^{\mu T}, \quad (4)$$

$$v = \text{Var}(S_T) = S_0^2 e^{2\mu T} (e^{\sigma^2 T} - 1), \quad (5)$$

$$q_p = S_0 \exp\{(\mu - \frac{1}{2}\sigma^2)T + \sigma\sqrt{T}\Phi^{-1}(p)\}. \quad (6)$$

对于本文选择的 GBM 基准 $S_0 = 100$ 、 $\mu = 0.05$ 、 $\sigma = 0.30$ 、 $T = 1$ ，理论均值为 105.1271，方差为 1040.7868（四舍五入）。GBM 参数是实验选择；非仿射模型的参数由题目规定。

1.2 在同一条布朗路径上比较三种方法

令 $h = T/N$ ， $\Delta W_n \sim N(0, h)$ 。精确模拟使用

$$S_{n+1} = S_n \exp\{(\mu - \frac{1}{2}\sigma^2)h + \sigma\Delta W_n\}. \quad (7)$$

基于价格的 EM 和标量 Milstein 更新分别为

$$S_{n+1}^E = S_n^E (1 + \mu h + \sigma \Delta W_n), \quad (8)$$

$$S_{n+1}^M = S_n^M \{1 + \mu h + \sigma \Delta W_n + \frac{1}{2}\sigma^2[(\Delta W_n)^2 - h]\}. \quad (9)$$

额外项来自 $\frac{1}{2}b(S)b'(S)[(\Delta W)^2 - h]$ ，其中 $b(S) = \sigma S$ [2]。在通常的正则性假设下，终值强阶分别为 1/2 和 1；对于合适的光滑测试函数，弱阶为 1。如果把 EM 直接用在 GBM 的对数价格上，网格点处的转移反而是精确的，因为噪声是加性的，Milstein 修正为零，无法用它验证非平凡的一阶比较。

2 蒙特卡洛方法

2.1 耦合与不确定性

先在最细网格上生成独立路径。粗网格的一个布朗增量等于对应细增量之和：

$$\Delta W_n^{(h)} = \sum_{j=nr}^{(n+1)r-1} \Delta W_j^{(\delta)}, \quad h = r\delta. \quad (10)$$

对于 GBM，精确终值使用同一个总增量 W_T 。对于非仿射模型，粗网格和参考网格也使用配对的布朗驱动。如果每个分辨率都独立生成随机数，路径之间会保留一个不随步长消失的差异，强收敛实验就失去了意义。

对 M 条独立路径，定义 $A_i(h) = |S_{T,i}^{(h)} - S_{T,i}^{\text{ref}}|$ 。终值 L^1 强误差估计量及其近似 95% 区间为

$$\hat{e}_s(h) = M^{-1} \sum_i A_i(h), \quad \hat{e}_s(h) \pm 1.96 s_A / \sqrt{M}. \quad (11)$$

经验阶数是在明确给定的拟合窗口上，对 $\log \hat{e}_s$ 关于 $\log h$ 做最小二乘拟合所得斜率。由于不同步长之间共享随机路径，点之间相关；这里的斜率是描述性结果，并没有声称有独立回归的置信区间。

对于收益函数 φ ，使用带符号的配对差

$$D_i(h) = \varphi(S_{T,i}^{(h)}) - \varphi(S_{T,i}^{\text{ref}}), \quad \hat{b}(h) = \overline{D}, \quad \text{CI}_{95} = \overline{D} \pm 1.96 s_D / \sqrt{M}. \quad (12)$$

弱误差是 $|\mathbb{E}[D]|$ ，不是 $\mathbb{E}|D|$ 。即使区间跨过零，也保留这个带符号的结果。这些区间只量化抽样误差，不包括数值参考本身的时间离散偏差。

2.2 解析 GBM 的弱均值偏差

对于两种方法，条件期望下的乘子都是 $1 + \mu h$ 。因此

$$\mathbb{E}[S_N^E] = \mathbb{E}[S_N^M] = S_0(1 + \mu h)^{T/h}, \quad (13)$$

$$b_{\text{exact}}(h) = S_0(1 + \mu h)^{T/h} - S_0 e^{\mu T}, \quad (14)$$

$$b_{\text{exact}}(h) = -\frac{1}{2} S_0 e^{\mu T} \mu^2 T h + O(h^2). \quad (15)$$

这说明当前非退化参数下，均值偏差为一阶。这是验证目标，不是把解析答案替换成蒙特卡洛估计。

模拟还构造了均值为零的控制变量 C_i ，并估计 $\overline{D - \beta^\top C}$ 。系数 β 在独立的预实验样本上拟合，然后固定用于正式样本，因此正式估计仍保持无偏；预实验不计入报告的正式路径数。完整控制变量公式和实现保留在随附的 `gbm.py` 中。

3 模型与实验方案

3.1 非仿射随机波动率

令 $X = \log S$, 题目规定的系统为

$$dX_t = \{\mu - \frac{1}{2}g(Y_t)^2\} dt + g(Y_t) dW_t^{(1)}, \quad (16)$$

$$dY_t = \kappa(\theta - Y_t) dt + \xi \sqrt{1 + Y_t^2} dW_t^{(2)}, \quad (17)$$

$$g(y) = \sigma_{\min} + \frac{\sigma_{\max} - \sigma_{\min}}{1 + e^{-y}}, \quad d\langle W^{(1)}, W^{(2)} \rangle_t = \rho dt. \quad (18)$$

表 1: 题目规定的非仿射基准参数。

S_0	Y_0	μ	κ	θ	ξ
100	0	0.05	2	-0.2	0.6
ρ	$\sigma_{\min}$	$\sigma_{\max}$	T	X_0	行权价 K
-0.7	0.10	0.50	1	$\log 100$	100

从相互独立的标准正态变量 Z_1, Z_2 出发, 生成

$$\Delta W^{(1)} = \sqrt{h} Z_1, \quad \Delta W^{(2)} = \sqrt{h}(\rho Z_1 + \sqrt{1 - \rho^2} Z_2). \quad (19)$$

实现的 EM 步是在左端点同时更新:

$$X_{n+1} = X_n + [\mu - \frac{1}{2}g(Y_n)^2]h + g(Y_n)\Delta W_n^{(1)}, \quad (20)$$

$$Y_{n+1} = Y_n + \kappa(\theta - Y_n)h + \xi \sqrt{1 + Y_n^2} \Delta W_n^{(2)}, \quad (21)$$

$$S_{n+1} = \exp(X_{n+1}). \quad (22)$$

两条更新式都使用旧值 Y_n 。如果先更新 Y , 再用 Y_{n+1} 更新第一条式子, 就改变了离散方法。稳定实现的 logistic 函数避免指数溢出; 程序还检查状态有限以及价格为正。

3.2 网格与可复现性

表 2: 计算方案; 所有网格都是 2 的幂次嵌套网格。

项目	数值	项目	数值
GBM 正式路径数	160,000	独立预实验路径数	20,000
GBM 随机种子	2026090804	预实验种子	2026090805
GBM 网格 N	8 至 1024	GBM 批大小	2000
非仿真路径数	100,000	随机种子	2026090804
粗网格 N	8,16,32,64,128,256	参考网格 N	2048,4096,8192
GBM 耗时	30.9 秒	非仿真耗时	107.8 秒

所有计算使用双精度和固定的 NumPy 随机数生成器; 正式路径分批处理, 以限制内存。随机种子、批大小、软件版本、耗时和完整精度结果都保存在 JSON 文件中。实验不使用外部市场数据。GBM 在价格变

量上比较精确解、EM 与 Milstein; 非仿射模型使用逐渐加密的 EM 参考。收益函数为 $\varphi(S) = (S - 100)^+$, 即在题目给定漂移下的未贴现期望看涨收益。没有定价测度和贴现率, 因此不将它解释为风险中性期权价格。

4 GBM 数值结果

4.1 强收敛




图 1: 耦合 GBM 的终值 L^1 误差。误差棒是逐点 95% 蒙特卡洛区间，许多区间小于标记。参考线表示 1/2 阶和 1 阶。

表 3: GBM 强误差估计及 95% 区间半宽。

h	EM	Milstein
1/8	1.84750 ± 0.00809	0.17127 ± 0.00100
1/16	1.32218 ± 0.00562	0.09096 ± 0.00048
1/32	0.93847 ± 0.00396	0.04697 ± 0.00023
1/64	0.66641 ± 0.00278	0.02391 ± 0.00011
1/128	0.47071 ± 0.00196	0.01209 ± 0.00006
1/256	0.33297 ± 0.00139	0.00610 ± 0.00003
1/512	0.23550 ± 0.00098	0.00306 ± 0.00001
1/1024	0.16658 ± 0.00069	0.00153 ± 0.00001

在窗口 $N=64,128,256,512,1024$ 上，EM 和 Milstein 的拟合斜率分别为 0.500 和 0.991。这与理论区别一致：EM 没有包含二次随机增量，而 Milstein 加入了该项。在最细步长下，Milstein 的路径误差明显更小。由于两种方法使用完全相同的布朗路径，差异来自更新公式，而非不同随机实现。

精确解在模拟网格点上没有时间离散误差。重新排列求和可能造成极小的浮点差异，但那不是收敛阶。这里比较的是终值误差，而不是整条路径上的最大误差；后者是另一种诊断。

4.2 弱收敛与方差缩减




图 2: GBM 均值偏差的大小。图中将控制变量后的配对估计与解析离散均值偏差比较；原始估计和区间保留在数值表中。

表 4: 带符号的弱偏差；表中给出控制后的估计和 95% 区间半宽。

h	解析偏差	EM (控制后)	Milstein (控制后)
1/8	-1.636×10^{-2}	$-1.649 \times 10^{-2} \pm 1.940 \times 10^{-4}$	$-1.629 \times 10^{-2} \pm 9.901 \times 10^{-5}$
1/32	-4.102×10^{-3}	$-4.096 \times 10^{-3} \pm 2.811 \times 10^{-5}$	$-4.106 \times 10^{-3} \pm 1.399 \times 10^{-5}$
1/128	-1.026×10^{-3}	$-1.025 \times 10^{-3} \pm 3.653 \times 10^{-6}$	$-1.027 \times 10^{-3} \pm 1.810 \times 10^{-6}$
1/512	-2.566×10^{-4}	$-2.567 \times 10^{-4} \pm 4.660 \times 10^{-7}$	$-2.566 \times 10^{-4} \pm 2.301 \times 10^{-7}$
1/1024	-1.283×10^{-4}	$-1.284 \times 10^{-4} \pm 1.649 \times 10^{-7}$	$-1.283 \times 10^{-4} \pm 8.144 \times 10^{-8}$

虽然两种方法的强误差不同，但它们的解析均值偏差相同。解析偏差的拟合阶数为 0.9993；在给定数据上，控制后的蒙特卡洛斜率为 0.999 和 1.000。这些结果要结合区间解读，不能代替式 (14)。在很小的 h 下，未经控制的 EM 配对估计噪声太大，难以可靠分辨这个小偏差。

控制变量的作用是减少抽样噪声而不改变估计目标。如果 C 的均值已知为零，那么对固定 β 有 $\mathbb{E}[D - \beta C] = \mathbb{E}[D]$ ；选择与 D 相关的 C 可以显著降低样本平均的方差。实现使用五个由同一批布朗增量计算的控制变量，在独立的 20,000 条预实验路径上拟合系数，再固定到 160,000 条正式路径上。它们是降噪工具，不是新的收敛方法。

在 $N = 1024$ 的 EM 实验中，原始配对标准误差约为 5.46×10^{-4} ，大于解析偏差的绝对值 1.28×10^{-4} ；控制后标准误差降为 8.41×10^{-8} 。这解释了为什么使用方差缩减。Milstein 在该网格上的原始配对区间已经不跨零。解析偏差只用于核对模拟结果，没有代替模拟估计。

4.3 分布与正值性




图 3: GBM 终值分布与精确对数正态定律的比较。直方图用于检查抽样形状, 分位数提供更精细的分布比较。

表 5: 终值分位数; 数值列使用 $h = 1/8$ 。

p	对数正态理论值	精确模拟	EM	Milstein
0.01	50.012	49.928	48.387	50.213
0.05	61.357	61.378	60.512	61.615
0.25	82.091	82.151	82.303	82.263
0.50	100.501	100.557	101.088	100.582
0.75	123.041	123.164	123.653	123.057
0.95	164.618	164.485	163.370	164.043
0.99	201.961	202.402	198.376	201.539

精确模拟的均值为 105.1987, 方差为 1045.0120, 均值区间为 [105.0403, 105.3571]。理论均值为 105.1271, 方差为 1040.7868。即使是精确模拟, 经验矩和分位数仍会有抽样波动, 不能把它们描述为离散误差。

当 $S_n > 0$ 时, EM 一步更新得到负值的概率为

$$\mathbb{P}(S_{n+1}^E < 0 \mid S_n > 0) = \Phi\left(-\frac{1 + \mu h}{\sigma\sqrt{h}}\right). \quad (23)$$

对于 Milstein, 配方得到乘子

$$\frac{1}{2}\sigma^2(\Delta W + 1/\sigma)^2 + \frac{1}{2} + (\mu - \frac{1}{2}\sigma^2)h. \quad (24)$$

它只有在 $(\sigma^2 - 2\mu)h > 1$ 时才可能为负。当前参数满足 $\sigma^2 - 2\mu = -0.01$, 所以 Milstein 对任意 $h > 0$ 都为正; 一般参数下则不一定。

表 6: GBM 负终值频率: 每种方法、每个网格均模拟 160,000 条路径。

N	EM: $S_N < 0$	Milstein: $S_N < 0$
8, 16, 32, 64	0/160,000 (0%)	0/160,000 (0%)
128, 256, 512, 1024	0/160,000 (0%)	0/160,000 (0%)

保存的计数实际统计的是 $S_N \leq 0$, 全部为零, 因此严格负值的频率也为零。这是终值频率, 不是“路径中途曾经为负”的频率; 本诊断没有保存 GBM 的所有中间价格。观察到零次负值不能证明 EM 保持正值。负价格可能影响非线性收益估计; 将负值截成零也会改变算法。本文没有进行截断。

5 非仿真模型的数值结果

5.1 相对于数值参考的强差




图 4: 相对于三层耦合 EM 参考网络的终值强差。参考是数值解, 因此曲线不是相对于精确解的误差。

表 7: 相对于 $h_{\text{ref}} = 1/8192$ 的强差; 给出 95% 区间半宽。

h	$\mathbb{E} S_h - S_{\text{ref}} $	最近一次参考差/强差
1/8	1.25354 ± 0.00702	3.2%
1/16	0.90087 ± 0.00489	4.5%
1/32	0.63818 ± 0.00341	6.3%
1/64	0.45176 ± 0.00241	8.9%
1/128	0.31854 ± 0.00170	12.6%
1/256	0.22323 ± 0.00119	18.0%

相对于最细参考, 在 $N=8, 16, 32, 64$ 上的经验斜率为 0.491。它与该窗口内大约半阶的强收敛行为一致。当粗网格接近参考网格时, 曲线会弯曲: 两个相近的离散解可能彼此很接近, 但仍共同偏离连续时间 SDE 的解。

若 S^* 表示未知的精确终值, 则反三角不等式给出

$$|\mathbb{E}|S_h - S^*| - \mathbb{E}|S_h - S_r|| \leq \mathbb{E}|S_r - S^*|. \quad (25)$$

右端未知。把 r 换成更细网格, 测到的是参考敏感性, 而不是未知的精确误差。因此下文单独报告参考网格的变化, 不把包含最细粗网格的斜率称为精确验证。

5.2 弱收益差




图 5: 相对于最细 EM 参考的看涨收益带符号配对差。误差棒为 95% 抽样区间；零线帮助判断偏差符号是否可分辨。

表 8: 相对于 $h_{\text{ref}} = 1/8192$ 的带符号配对收益差。

h	估计偏差	95% 区间	是否排除零
1/8	0.02579	[0.01672, 0.03486]	是
1/16	0.01048	[0.00405, 0.01691]	是
1/32	0.00540	[0.00089, 0.00991]	是
1/64	0.00172	[-0.00148, 0.00492]	否
1/128	0.00096	[-0.00130, 0.00322]	否
1/256	0.00034	[-0.00124, 0.00192]	否

在 $N = 64, 128, 256$ 时, 95% 区间包含零。因此不能为完整网格范围指定弱阶。最细参考的收益估计为 14.53804, 区间为 [14.40515, 14.67093]。收益函数在行权价处有一个折角, 因此不能不加说明地套用光滑测试函数的弱阶理论。配对区间用于判断估计差异能否从抽样噪声中分辨; 它们不包括数值参考的偏差。

5.3 为什么 call payoff 比均值更有信息?

连续模型满足 $\mathbb{E}[S_T] = 100e^{0.05}$ 。但是, 对数 EM 在每一个步长下也保留这个均值。令 $g_n = g(Y_n)$, 在一步开始时 S_n 和 g_n 已知, 而下一增量服从 $N(0, h)$, 所以

$$\begin{aligned}
 \mathbb{E}[S_{n+1} | \mathcal{F}_{t_n}] &= S_n e^{(\mu - g_n^2/2)h} \mathbb{E}[e^{g_n \Delta W_n^{(1)}} | \mathcal{F}_{t_n}] \\
 &= S_n e^{(\mu - g_n^2/2)h} e^{g_n^2 h/2} = S_n e^{\mu h}.
 \end{aligned} \tag{26}$$

重复这个条件期望计算便得到 $\mathbb{E}[S_N] = 100e^{0.05}$ 。因此均值是有用的实现检查, 但它对该方案没有时间离散偏差, 无法显示弱收敛阶。

均值相同不代表期望收益相同。例如，价格总是 100，和以相同概率取 80 或 120 的价格，都有均值 100；但执行价为 100 的收益 $(S - 100)^+$ 的期望分别为 0 和 10。Call payoff 能观察均值看不到的终值分布差异。它的期望没有被 log-EM 自动保持，因此改变步长可能产生真正的弱偏差。这就是它在本实验中作为非平凡弱观测量的原因；它不是唯一选择，也不保证每个网格都能测出显著偏差。

6 参考网格加密与验证

表 9: 数值参考的耦合加密。

参考加密 $N_a \rightarrow N_b$	强差	带符号收益差及 95% 区间
2048 $\rightarrow$ 4096	0.05679 ± 0.00030	-0.000023 [-0.000423, 0.000377]
4096 $\rightarrow$ 8192	0.04016 ± 0.00021	0.000094 [-0.000188, 0.000376]

相邻参考网格的平均绝对差从 2048 与 4096 步时的 0.05679, 降至 4096 与 8192 步时的 0.04016。为了判断它的相对规模, 将 0.04016 除以粗网格到最细参考的强差, 可得 $N = 8, 16, 32, 64$ 时约为 3.2%、4.5%、6.3% 和 8.9%; 在 $N = 128, 256$ 时升至 12.6% 和 18.0%。因此, 在更细的粗网格上, 参考分辨率的影响相对更大。本文保留原先 $N = 8, 16, 32, 64$ 的拟合窗口, 并将其斜率称为经验结果。之前报告使用 10% 作为作者自行选择的经验规则; 它不是题目要求, 也不是由引用文献证明的通用容差标准。因此本文不把它当作通过或失败的判据。这些变化提供的是参考加密的证据, 不是相对于未知精确解的误差界。

表 10: 最细非仿射网格上的布朗增量与状态诊断。

项目	观测值	目标或范围
增量方差 1	1.221×10^{-4}	1.221×10^{-4}
增量方差 2	1.221×10^{-4}	1.221×10^{-4}
增量相关系数	-0.699675	-0.700000
抽样增量数	4,194,304	预先指定的第一批
总路径更新次数	1,484,000,000	所有网格
中间状态有限	通过	X 和 Y
价格为正且有限	通过	所有观测状态

两个布朗增量的方差目标都是 h , 目标相关系数为 -0.7 。这些诊断来自生成的细增量, 而不是从生成器公式推断出来。状态检查包括中间更新, 因为只有终值有限并不能排除中间步骤出现无效更新。

最细网格的均值为 105.08796, 95% 区间为 [104.89962, 105.27629]; 对应的未贴现收益估计为 14.53804, 区间为 [14.40515, 14.67093]。后一个区间只描述最细离散模型的抽样不确定性; 要评估其时间偏差, 仍然需要参考加密表。

按照题目要求, 本模型使用 EM。两维噪声下的 Milstein 方法还需要额外的交叉噪声项, 不能直接把 GBM 的标量公式复制过来; 本次比较不需要实现这个扩展。

7 讨论与结论

GBM 实验支持三个结论。第一，与精确解进行共同路径比较，可以观察到 Milstein 的强收敛优势。第二，强阶和弱阶回答不同问题：尽管逐路径误差不同，两种方法对终值均值却有相同的一阶偏差。第三，分布和正值性检查提供了单个均值无法提供的信息。当 GBM 的精确转移可用时，对数价格模拟更直接；在价格上离散仍然是一个有用的受控验证实验。

对于非仿射模型，有界正波动率和指数价格表示使测试路径上的价格保持有限且为正。嵌套网格比较提供了加密收敛的证据，也揭示了数值参考会如何影响测得的阶数；它们不能给出精确误差。特别是，当收益区间包含零时，不能宣称已经测出弱收敛阶；当参考差异与粗网格差异相当时，对比较精度也必须保持谨慎。

主要计算取舍是路径数和时间分辨率之间的平衡。将 h 减半，大约使每条路径的更新次数加倍；将 M 增加四倍，蒙特卡洛标准误差通常约减半。配对差和控制变量处理抽样部分，参考加密处理离散部分。增加路径数不能修复分辨率不足的参考，减小步长也不能单独消除抽样不确定性。

本文完成了题目第四方向的主要要求：精确解-EM-Milstein 比较、使用共同路径的强弱收敛、对数正态分布验证、抽样区间以及非仿射模型的嵌套参考检查。没有用确定性稳定性图或标量 Milstein 扩展替代这些要求。正值性诊断报告的是终值频率，并未统计所有中间更新；结论限于本文的参数、时间区间、误差范数、样本数和拟合窗口。

可复现性

随附 Python 文件和保存结果记录了随机种子、样本数量和更新公式。本文使用已有实验结果，没有把它描述为一次新的完整模拟运行。附录给出核心更新和复现命令。

AI 致谢

本报告使用 OpenAI Codex 辅助解释数学方法、开发和检查 Python 代码、完成数值计算，以及起草和修改报告。AI 也帮助改善了讨论和结果呈现的清晰度。

参考文献

- [1] *Problem Pack: Five Suggested Directions for the ODE IVP Project*, 课程作业文件, Direction 4, 第 6–7 页。
- [2] D. J. Higham. An algorithmic introduction to numerical simulation of stochastic differential equations. *SIAM Review*, 43(3):525–546, 2001. doi:10.1137/S0036144500378302。
- [3] P. E. Kloeden and E. Platen. *Numerical Solution of Stochastic Differential Equations*. Springer, 1992. doi:10.1007/978-3-662-12616-5。

A Python 实现与复现

下面的代码列出核心数学操作。可执行模块还实现了分批计算、控制变量预实验拟合、不确定性估计、诊断、导出和绘图；完整源码随报告提供。

Listing 1: 核心 SDE 更新和共同路径误差统计。

```

1 import numpy as np
2
3 def coarsen(dw_fine, n_coarse):
4     m, n_fine = dw_fine.shape
5     assert n_fine % n_coarse == 0
6     return dw_fine.reshape(m, n_coarse, -1).sum(axis=2)
7
8 def gbm_terminal(dw, s0=100., mu=.05, sigma=.3, T=1.):
9     h = T / dw.shape[1]
10    exact = s0 * np.exp((mu-.5*sigma**2)*T
11                      + sigma*dw.sum(axis=1))
12    em = s0 * np.prod(1 + mu*h + sigma*dw, axis=1)
13    mil = s0 * np.prod(1 + mu*h + sigma*dw
14                      + .5*sigma**2*(dw*dw-h), axis=1)
15    return exact, em, mil
16
17 def log_em_step(x, y, dw1, dw2, h):
18     # 两个右端都使用旧时刻的数值。
19     sigmoid = np.exp(-np.logaddexp(0., -y))
20     g = .1 + .4*sigmoid
21     x_new = x + (.05-.5*g*g)*h + g*dw1
22     y_new = y + 2*(-.2-y)*h + .6*np.hypot(1.,y)*dw2
23     return x_new, y_new
24
25 def mean_ci(values):
26     m = len(values)
27     mean = np.mean(values)
28     half_width = 1.96*np.std(values, ddof=1)/np.sqrt(m)
29     return mean, mean-half_width, mean+half_width
30
31 # 从独立标准正态数生成相关布朗增量:
32 # dw1 = sqrt(h)*z1
33 # dw2 = sqrt(h)*(rho*z1 + sqrt(1-rho**2)*z2)
34 # 强误差: mean_ci(abs(s_coarse-s_reference))
35 # 弱误差: mean_ci(maximum(s_coarse-100,0)
36 #               -maximum(s_reference-100,0))

```

在原项目目录中运行:

```
python -m pip install -r requirements.txt
python run_all.py
```

在不重新模拟的情况下核对已有结果:

```
python verify.py
```

在本目录中编译中文报告:

```
tectonic Coursework_Undergraduate_中文.tex
```

原项目的 results/ 保存机器可读的表格和日志, figures/ 保存矢量 PDF 和 PNG 图。附录代码用于解释核心算法; 完整复现需要两个模拟模块, 而只重建报告表格不会重新模拟路径。