

金融随机微分方程的数值模拟

第四题：GBM 基准与非仿射波动率

课程作业报告（中文译本）

2026 年 9 月

摘要

本文围绕三个问题展开：哪种方法能更准确地逼近同一条随机路径；路径更准确是否意味着均值也更准确；没有精确解时如何评估结果。几何布朗运动 (GBM) 为 Euler-Maruyama (EM) 和 Milstein 方法提供精确基准，两者测得的终值强阶分别为 0.500 和 0.991，但均值却具有相同的一阶偏差。对于需要数值参考的非仿射随机波动率模型，三层嵌套参考给出的经验强斜率都接近半阶；较细网格上的看涨收益差则还无法从抽样噪声中可靠分辨。最后，用已有配对终值完成一个样本量实验，说明增加路径数如何减少抽样不确定性，以及为什么它不能消除时间离散偏差。

目录

1 引言与理论背景	2
2 蒙特卡洛方法	3
3 模型与实验方案	4
4 哪种方法能更准确地逼近同一条随机路径？	5
5 路径更准确，均值也一定更准确吗？	6
6 没有精确解时，怎样判断结果是否可信？	8
7 讨论与结论	12
A Python 实现与复现	13

可复现性：随报告提供完整 Python 源码、随机种子、数值表格、图形和运行记录。报告中的置信区间是逐点蒙特卡洛区间。

1 引言与理论背景

题目要求用强弱收敛、抽样不确定性和嵌套网格评估 SDE 方法 [1]。GBM 的精确解便于检查程序和方法；非仿射模型则说明，没有精确采样公式时，这套验证思路需要怎样调整。

结果部分依次回答三个问题：哪种方法能更准确地逼近同一条随机路径（第 4 节）；路径更准确是否意味着均值也更准确（第 5 节）；没有精确解时如何评估结果（第 6 节）。始终区分两个数量：增加时间步数 N 改善时间分辨率，增加路径数 M 改善统计估计精度。

1.1 GBM 及其精确转移

当 $S_0 > 0$ 时，Itô 随机微分方程和对数变换为

$$dS_t = \mu S_t dt + \sigma S_t dW_t, \quad (1)$$

$$dX_t = (\mu - \frac{1}{2}\sigma^2) dt + \sigma dW_t, \quad X_t = \log S_t. \quad (2)$$

Itô 修正项非常重要：漏掉 $-\sigma^2/2$ 会改变价格均值。积分得到

$$S_t = S_0 \exp\{(\mu - \frac{1}{2}\sigma^2)t + \sigma W_t\}. \quad (3)$$

因此 S_T 服从对数正态分布，且

$$m = \mathbb{E}[S_T] = S_0 e^{\mu T}, \quad (4)$$

$$v = \text{Var}(S_T) = S_0^2 e^{2\mu T} (e^{\sigma^2 T} - 1), \quad (5)$$

$$q_p = S_0 \exp\{(\mu - \frac{1}{2}\sigma^2)T + \sigma\sqrt{T}\Phi^{-1}(p)\}. \quad (6)$$

对于本文选择的 GBM 基准 $S_0 = 100$ 、 $\mu = 0.05$ 、 $\sigma = 0.30$ 、 $T = 1$ ，理论均值为 105.1271，方差为 1040.7868（四舍五入）。GBM 参数是实验选择；非仿射模型的参数由题目规定。

1.2 在同一条布朗路径上比较三种方法

令 $h = T/N$ ， $\Delta W_n \sim N(0, h)$ 。精确模拟使用

$$S_{n+1} = S_n \exp\{(\mu - \frac{1}{2}\sigma^2)h + \sigma\Delta W_n\}. \quad (7)$$

基于价格的 EM 和标量 Milstein 更新分别为

$$S_{n+1}^E = S_n^E (1 + \mu h + \sigma \Delta W_n), \quad (8)$$

$$S_{n+1}^M = S_n^M \{1 + \mu h + \sigma \Delta W_n + \frac{1}{2}\sigma^2[(\Delta W_n)^2 - h]\}. \quad (9)$$

额外项来自 $\frac{1}{2}b(S)b'(S)[(\Delta W)^2 - h]$ ，其中 $b(S) = \sigma S$ [2]。在通常的正则性假设下，终值强阶分别为 $1/2$ 和 1 ；对于合适的光滑测试函数，弱阶为 1 。如果把 EM 直接用在 GBM 的对数价格上，网格点处的转移反而是精确的，因为噪声是加性的，Milstein 修正为零，无法用它验证非平凡的一阶比较。

2 蒙特卡洛方法

2.1 耦合与不确定性

先在最细网格上生成独立路径。粗网格的一个布朗增量等于对应细增量之和：

$$\Delta W_n^{(h)} = \sum_{j=nr}^{(n+1)r-1} \Delta W_j^{(\delta)}, \quad h = r\delta. \quad (10)$$

对于 GBM，精确终值使用同一个总增量 W_T 。对于非仿射模型，粗网格和参考网格也使用配对的布朗驱动。如果每个分辨率都独立生成随机数，路径之间会保留一个不随步长消失的差异，强收敛实验就失去了意义。

对 M 条独立路径，定义 $A_i(h) = |S_{T,i}^{(h)} - S_{T,i}^{\text{ref}}|$ 。终值 L^1 强误差估计量及其近似 95% 区间为

$$\hat{e}_s(h) = M^{-1} \sum_i A_i(h), \quad \hat{e}_s(h) \pm 1.96 s_A / \sqrt{M}. \quad (11)$$

经验阶数是在明确给定的拟合窗口上，对 $\log \hat{e}_s$ 关于 $\log h$ 做最小二乘拟合所得斜率。由于不同步长之间共享随机路径，点之间相关；这里的斜率是描述性结果，并没有声称有独立回归的置信区间。

对于收益函数 φ ，使用带符号的配对差

$$D_i(h) = \varphi(S_{T,i}^{(h)}) - \varphi(S_{T,i}^{\text{ref}}), \quad \hat{b}(h) = \overline{D}, \quad \text{CI}_{95} = \overline{D} \pm 1.96 s_D / \sqrt{M}. \quad (12)$$

弱误差是 $|\mathbb{E}[D]|$ ，不是 $\mathbb{E}|D|$ 。即使区间跨过零，也保留这个带符号的结果。这些区间只量化抽样误差，不包括数值参考本身的时间离散偏差。

2.2 GBM 均值弱偏差的解析表达式

对于两种方法，条件期望下的乘子都是 $1 + \mu h$ 。因此

$$\mathbb{E}[S_N^E] = \mathbb{E}[S_N^M] = S_0(1 + \mu h)^{T/h}, \quad (13)$$

$$b_{\text{exact}}(h) = S_0(1 + \mu h)^{T/h} - S_0 e^{\mu T}, \quad (14)$$

$$b_{\text{exact}}(h) = -\frac{1}{2} S_0 e^{\mu T} \mu^2 T h + O(h^2). \quad (15)$$

这说明当前非退化参数下，均值偏差为一阶。这个解析表达式用于核对模拟结果，本身不是蒙特卡洛估计。

模拟还构造了均值为零的控制变量 C_i ，并估计 $\overline{D - \beta^\top C}$ 。系数 β 在独立的预实验样本上拟合，然后固定用于正式样本，因此正式估计仍保持无偏；预实验不计入报告的正式路径数。完整控制变量公式和实现保留在随附的 `gbm.py` 中。

3 模型与实验方案

3.1 非仿射随机波动率

令 $X = \log S$, 题目规定的系统为

$$dX_t = \{\mu - \frac{1}{2}g(Y_t)^2\} dt + g(Y_t) dW_t^{(1)}, \quad (16)$$

$$dY_t = \kappa(\theta - Y_t) dt + \xi \sqrt{1 + Y_t^2} dW_t^{(2)}, \quad (17)$$

$$g(y) = \sigma_{\min} + \frac{\sigma_{\max} - \sigma_{\min}}{1 + e^{-y}}, \quad d\langle W^{(1)}, W^{(2)} \rangle_t = \rho dt. \quad (18)$$

表 1: 题目规定的非仿射基准参数。

S_0	Y_0	μ	κ	θ	ξ
100	0	0.05	2	-0.2	0.6
ρ	$\sigma_{\min}$	$\sigma_{\max}$	T	X_0	行权价 K
-0.7	0.10	0.50	1	$\log 100$	100

从相互独立的标准正态变量 Z_1, Z_2 出发, 生成

$$\Delta W^{(1)} = \sqrt{h} Z_1, \quad \Delta W^{(2)} = \sqrt{h}(\rho Z_1 + \sqrt{1 - \rho^2} Z_2). \quad (19)$$

实现的 EM 步是在左端点同时更新:

$$X_{n+1} = X_n + [\mu - \frac{1}{2}g(Y_n)^2]h + g(Y_n)\Delta W_n^{(1)}, \quad (20)$$

$$Y_{n+1} = Y_n + \kappa(\theta - Y_n)h + \xi \sqrt{1 + Y_n^2} \Delta W_n^{(2)}, \quad (21)$$

$$S_{n+1} = \exp(X_{n+1}). \quad (22)$$

两条更新式都使用旧值 Y_n 。如果先更新 Y , 再用 Y_{n+1} 更新第一条式子, 就改变了离散方法。稳定实现的 logistic 函数避免指数溢出; 程序还检查状态有限以及价格为正。

3.2 网格与可复现性

表 2: 计算方案; 所有网格都是 2 的幂次嵌套网格。

项目	数值	项目	数值
GBM 正式路径数	160,000	独立预实验路径数	20,000
GBM 随机种子	2026090804	预实验种子	2026090805
GBM 网格 N	8 至 1024	GBM 批大小	2000
非仿射路径数	100,000	随机种子	2026090804
粗网格 N	8,16,32,64,128,256	参考网格 N	2048,4096,8192
GBM 耗时	30.9 秒	非仿射耗时	107.8 秒

所有计算使用双精度和固定的 NumPy 随机数生成器; 正式路径分批处理, 以限制内存。随机种子、批大小、软件版本、耗时和完整精度结果都保存在 JSON 文件中。实验不使用外部市场数据。GBM 在价格变量上比较精确解、EM 与 Milstein; 非仿射模型使用逐渐加密的 EM 参考。收益函数为 $\varphi(S) = (S - 100)^+$, 即在题目给定漂移下的未贴现期望看涨收益。没有定价测度和贴现率, 因此不将它解释为风险中性期权价格。

4 哪种方法能更准确地逼近同一条随机路径?

4.1 GBM 的强收敛




图 1: 耦合 GBM 的终值 L^1 误差。误差棒是逐点 95% 蒙特卡洛区间, 许多区间小于标记。参考线表示 1/2 阶和 1 阶。

表 3: GBM 强误差估计及 95% 区间半宽。

h	EM	Milstein
1/8	1.84750 ± 0.00809	0.17127 ± 0.00100
1/16	1.32218 ± 0.00562	0.09096 ± 0.00048
1/32	0.93847 ± 0.00396	0.04697 ± 0.00023
1/64	0.66641 ± 0.00278	0.02391 ± 0.00011
1/128	0.47071 ± 0.00196	0.01209 ± 0.00006
1/256	0.33297 ± 0.00139	0.00610 ± 0.00003
1/512	0.23550 ± 0.00098	0.00306 ± 0.00001
1/1024	0.16658 ± 0.00069	0.00153 ± 0.00001

在窗口 $N = 64, 128, 256, 512, 1024$ 上, EM 和 Milstein 的拟合斜率分别为 0.500 和 0.991。这与理论区别一致: EM 没有包含二次随机增量, 而 Milstein 加入了该项。在最细步长下, Milstein 的路径误差明显更小。由于两种方法使用完全相同的布朗路径, 差异来自更新公式, 而非不同随机实现。

半阶的含义是步长减半时, 误差约乘以 $1/\sqrt{2}$; 一阶则表示误差约减半。从 $N = 64$ 到 1024, 步长缩小 16 倍, EM 的误差从 0.66641 降至 0.16658, 约缩小 4.00 倍, 与 $\sqrt{16}$ 一致。Milstein 从 0.02391 降至 0.00153, 约缩小 15.6 倍, 接近 16 倍。这里的误差以价格为单位, 比较的是终值, 而不是整条路径的最大误差。精确网格值没有时间离散误差。

5 路径更准确，均值也一定更准确吗？

5.1 GBM 的弱收敛




图 2: GBM 均值偏差的大小。图中将控制变量后的配对估计与解析离散均值偏差比较；原始估计和区间保留在保存的 CSV 数据中。

表 4: 带符号的弱偏差；表中给出控制后的估计和 95% 区间半宽。

h	解析偏差	EM (控制后)	Milstein (控制后)
1/8	-1.636×10^{-2}	$-1.649 \times 10^{-2} \pm 1.940 \times 10^{-4}$	$-1.629 \times 10^{-2} \pm 9.901 \times 10^{-5}$
1/32	-4.102×10^{-3}	$-4.096 \times 10^{-3} \pm 2.811 \times 10^{-5}$	$-4.106 \times 10^{-3} \pm 1.399 \times 10^{-5}$
1/128	-1.026×10^{-3}	$-1.025 \times 10^{-3} \pm 3.653 \times 10^{-6}$	$-1.027 \times 10^{-3} \pm 1.810 \times 10^{-6}$
1/512	-2.566×10^{-4}	$-2.567 \times 10^{-4} \pm 4.660 \times 10^{-7}$	$-2.566 \times 10^{-4} \pm 2.301 \times 10^{-7}$
1/1024	-1.283×10^{-4}	$-1.284 \times 10^{-4} \pm 1.649 \times 10^{-7}$	$-1.283 \times 10^{-4} \pm 8.144 \times 10^{-8}$

对于均值，答案是否定的：虽然两种方法的强误差不同，它们的解析均值偏差却相同。每一步的期望乘子都是 $1 + \mu h$ ，因此式 (14) 同时适用于两者。解析偏差的拟合阶数为 0.9993，控制后的蒙特卡洛斜率分别为 0.999 和 1.000。这一结论针对均值这个观测量，并不表示两种方法对所有收益函数都有相同偏差。

控制变量的作用是减少抽样噪声而不改变估计目标。如果 C 的均值已知为零，那么对固定 β 有 $\mathbb{E}[D - \beta C] = \mathbb{E}[D]$ ；选择与 D 相关的 C 可以显著降低样本平均的方差。实现使用五个由同一批布朗增量计算的控制变量，在独立的 20,000 条预实验路径上拟合系数，再固定到 160,000 条正式路径上。它们是降噪工具，不是新的收敛方法。

表 5: GBM 在 $N = 1024$ 时，配对均值偏差估计的标准误差。

方法	控制变量处理前	控制变量处理后
EM	5.464e-04	8.415e-08
Milstein	5.258e-06	4.155e-08

表 5 解释了方差缩减的作用：EM 原始标准误差大于均值偏差的绝对值 1.28×10^{-4} ，而 Milstein 的原始区间已经不跨零。控制变量减少的是估计噪声，不改变时间更新方法及其偏差；解析偏差只作为核对目标。

5.2 分布与正值性




图 3: GBM 终值分布与精确对数正态定律的比较。直方图用于检查抽样形状，分位数提供更精细的分布比较。

表 6: 终值分位数；数值列使用 $h = 1/8$ 。

p	对数正态理论值	精确模拟	EM	Milstein
0.01	50.012	49.928	48.387	50.213
0.05	61.357	61.378	60.512	61.615
0.25	82.091	82.151	82.303	82.263
0.50	100.501	100.557	101.088	100.582
0.75	123.041	123.164	123.653	123.057
0.95	164.618	164.485	163.370	164.043
0.99	201.961	202.402	198.376	201.539

精确模拟的均值为 105.1987，方差为 1045.0120，均值区间为 [105.0403, 105.3571]。理论均值为 105.1271，方差为 1040.7868。即使是精确模拟，经验矩和分位数仍会有抽样波动，不能把它们描述为离散误差。

当 $S_n > 0$ 时，EM 一步更新得到负值的概率为

$$\mathbb{P}(S_{n+1}^E < 0 \mid S_n > 0) = \Phi\left(-\frac{1 + \mu h}{\sigma\sqrt{h}}\right). \quad (23)$$

对于 Milstein，配方得到乘子

$$\frac{1}{2}\sigma^2(\Delta W + 1/\sigma)^2 + \frac{1}{2} + (\mu - \frac{1}{2}\sigma^2)h. \quad (24)$$

它只有在 $(\sigma^2 - 2\mu)h > 1$ 时才可能为负。当前参数满足 $\sigma^2 - 2\mu = -0.01$ ，所以 Milstein 对任意 $h > 0$ 都为正；一般参数下则不一定。

表 7: GBM 负终值频率：每种方法、每个网格均模拟 160,000 条路径。

N	EM: $S_N < 0$	Milstein: $S_N < 0$
8, 16, 32, 64	0/160,000 (0%)	0/160,000 (0%)
128, 256, 512, 1024	0/160,000 (0%)	0/160,000 (0%)

保存的计数实际统计的是 $S_N \leq 0$ ，全部为零，因此严格负值的频率也为零。这是终值频率，不是“路径中途曾经为负”的频率；本诊断没有保存 GBM 的所有中间价格。观察到零次负值不能证明 EM 保持正值。负价格可能影响非线性收益估计；将负值截成零也会改变算法。本文没有进行截断。

6 没有精确解时，怎样判断结果是否可信？

6.1 相对于数值参考的强差




图 4: 相对于三层耦合 EM 参考网格的终值强差。参考是数值解，因此曲线不是相对于精确解的误差。

表 8: 相对于 $h_{\text{ref}} = 1/8192$ 的强差；给出 95% 区间半宽。

h	$\mathbb{E} S_h - S_{\text{ref}} $	最近一次参考差/强差
1/8	1.25354 ± 0.00702	3.2%
1/16	0.90087 ± 0.00489	4.5%
1/32	0.63818 ± 0.00341	6.3%
1/64	0.45176 ± 0.00241	8.9%
1/128	0.31854 ± 0.00170	12.6%
1/256	0.22323 ± 0.00119	18.0%

相对于最细参考，在 $N = 8, 16, 32, 64$ 上的经验斜率为 0.491。它与该窗口内大约半阶的强收敛行为一致。当粗网格接近参考网格时，曲线会弯曲：两个相近的离散解可能彼此很接近，但仍共同偏离连续时间 SDE 的解。

若 S^* 表示未知的精确终值，则反三角不等式给出

$$|\mathbb{E}|S_h - S^*| - \mathbb{E}|S_h - S_r|| \leq \mathbb{E}|S_r - S^*|. \quad (25)$$

右端未知。把 r 换成更细网格，测到的是参考敏感性，而不是未知的精确误差。因此，除了比较相邻参考解的差，本文还比较不同参考下拟合斜率的变化。

6.2 弱收益差




图 5: 相对于最细 EM 参考的看涨收益带符号配对差。误差棒为 95% 抽样区间；零线帮助判断偏差符号是否可分辨。

表 9: 相对于 $h_{\text{ref}} = 1/8192$ 的带符号配对收益差。

h	估计偏差	95% 区间	是否排除零
1/8	0.02579	[0.01672, 0.03486]	是
1/16	0.01048	[0.00405, 0.01691]	是
1/32	0.00540	[0.00089, 0.00991]	是
1/64	0.00172	[-0.00148, 0.00492]	否
1/128	0.00096	[-0.00130, 0.00322]	否
1/256	0.00034	[-0.00124, 0.00192]	否

在 $N = 8, 16, 32$ 时，区间不含零，因此这些较粗网格的收益差可以从抽样噪声中分辨。在 $N = 64, 128, 256$ 时，区间包含零，现有样本无法可靠判断偏差符号。这不证明偏差为零，也不足以完整网格范围指定弱阶。收益函数在行权价处有一个折角，因此不能不加说明地套用光滑测试函数的弱阶理论。配对区间用于判断估计差异能否从抽样噪声中分辨；它们不包括数值参考的偏差。

6.3 为什么使用看涨收益，而不只检查均值？

连续模型满足 $\mathbb{E}[S_T] = 100e^{0.05}$ 。但是，对数 EM 在每一个步长下也保留这个均值。令 $g_n = g(Y_n)$ ，在一步开始时 S_n 和 g_n 已知，而下一增量服从 $N(0, h)$ ，所以

$$\begin{aligned}\mathbb{E}[S_{n+1} | \mathcal{F}_{t_n}] &= S_n e^{(\mu - g_n^2/2)h} \mathbb{E}[e^{g_n \Delta W_n^{(1)}} | \mathcal{F}_{t_n}] \\ &= S_n e^{(\mu - g_n^2/2)h} e^{g_n^2 h/2} = S_n e^{\mu h}.\end{aligned}\tag{26}$$

这里 $\mathcal{F}_{t_n}$ 表示一步开始时已经掌握的信息。重复这个条件期望计算便得到 $\mathbb{E}[S_N] = 100e^{0.05}$ 。因此均值是有用的实现检查，但它对该方案没有时间离散偏差，无法显示弱收敛阶。

均值相同不代表期望收益相同。例如，价格总是 100，和以相同概率取 80 或 120 的价格，都有均值 100；但执行价为 100 的收益 $(S - 100)^+$ 的期望分别为 0 和 10。看涨收益能观察均值看不到的终值分布差异。它的期望没有被对数 EM 自动保持，因此改变步长可能产生真正的弱偏差。这就是它在本实验中作为非平凡弱观测量的原因；它不是唯一选择，也不保证每个网格都能测出显著偏差。

6.4 加密参考网格后，答案变化多大？

表 10: 数值参考的耦合加密。

参考加密 $N_a \rightarrow N_b$	强差	带符号收益差及 95% 区间
2048 $\rightarrow$ 4096	0.05679 ± 0.00030	$-0.000023 [-0.000423, 0.000377]$
4096 $\rightarrow$ 8192	0.04016 ± 0.00021	$0.000094 [-0.000188, 0.000376]$

相邻参考网格的平均绝对差从 2048 与 4096 步时的 0.05679，降至 4096 与 8192 步时的 0.04016，后者约为前者的 0.707 倍，与半阶缩放相容。在 $N = 8, 16, 32, 64$ 的拟合窗口内，0.04016 约占粗网格到最细参考强差的 3.2% 至 8.9%；在 $N = 128, 256$ 时，这一比例升至 12.6% 和 18.0%。因此，更细的粗网格相对更受参考分辨率影响，主要斜率使用参考影响相对较小的四个网格。这些比较衡量参考加密的敏感性，不构成相对于未知精确解的误差上界。

表 11: 固定拟合窗口 $N = 8, 16, 32, 64$ ，仅改变数值参考。

参考步数	经验强斜率
2048	0.496108
4096	0.493008
8192	0.491450

表 11 固定拟合窗口，只改变参考网格。三个斜率约为 0.496、0.493 和 0.491，说明这个窗口内的半阶趋势对这些参考选择较稳定。这是数值证据，不是精确误差上界。

表 12: 最细非仿射网格上的布朗增量与状态诊断。

项目	观测值	目标或范围
增量方差 1	1.221×10^{-4}	1.221×10^{-4}
增量方差 2	1.221×10^{-4}	1.221×10^{-4}
增量相关系数	-0.699675	-0.700000
抽样增量数	4,194,304	预先指定的第一批
总路径更新次数	1,484,000,000	所有网格
中间状态有限	通过	X 和 Y
价格为正且有限	通过	所有观测状态

两个布朗增量的方差目标都是 h ，目标相关系数为 -0.7 。这些诊断来自生成的细增量，而不是从生成器公式推断出来。状态检查包括中间更新，因为只有终值有限并不能排除中间步骤出现无效更新。

最细网格的均值为 105.08796，95% 区间为 $[104.89962, 105.27629]$ ；对应的未贴现收益估计为 14.53804，区间为 $[14.40515, 14.67093]$ 。后一个区间只描述最细离散模型的抽样不确定性；要评估其时间偏差，仍然需要参考加密表。

按照题目要求，本模型使用 EM。两维噪声下的 Milstein 方法还需要额外的交叉噪声项，不能直接把 GBM 的标量公式复制过来；本次比较不需要实现这个扩展。

6.5 一个样本量实验：增加路径数能改善什么？

固定粗网格 $N = 64$ 和参考网格 $N_{\text{ref}} = 8192$ ，从已保存的终值数组计算配对收益差：

$$D_i = (S_{T,i}^{(1/64)} - 100)^+ - (S_{T,i}^{(1/8192)} - 100)^+. \quad (27)$$

依保存顺序分别取前 10,000、40,000 和 100,000 对样本。这三个子集相互嵌套，共享观测，因此三组估计彼此相关，不是三次独立重复实验。没有重新模拟路径，也没有更换种子挑选结果。

表 13: 固定网格 $N = 64$ 与参考 $N_{\text{ref}} = 8192$ ；使用保存样本的嵌套前缀。

路径数 M	带符号收益差	标准误差	95% 区间
10,000	0.009045	0.005149	[-0.001048, 0.019137]
40,000	0.004942	0.002592	[-0.000139, 0.010022]
100,000	0.001722	0.001633	[-0.001479, 0.004923]

每个子集内部的不同路径独立，均值的标准误差为 $s_D/\sqrt{M}$ 。如果样本方差变化不大，路径数增加四倍，标准误差应约减半。表 13 中，它从 10,000 条路径时的 0.005149 降到 40,000 条时的 0.002592，比值为 0.503；在 100,000 条时为 0.001633，约为最初的 0.317，与 $1/\sqrt{10}$ 接近。因此，观测到的抽样不确定性按预期的规模下降。

三个区间仍然都包含零。增加路径数提高了精度，却不保证现有样本规模足以辨认这个偏差。点估计逐渐变小，也不能说明方法本身的偏差变小了：两层时间网格一直不变，三组估计针对的是同一个未知期望差。100,000 条路径的估计也不是其精确值。

实际意义。增加 M 减少抽样不确定性；增加 N 改变时间离散。本实验只检验前一种效果，不证明时间弱收敛阶，也不消除数值参考的偏差。细网格收益差无法分辨，说明的是统计分辨率的限制，不能据此认定真实偏差为零。

7 讨论与结论

路径精度。GBM 的精确值与数值值共用同一条布朗路径，因此能够直接比较。测得的强斜率 0.500 和 0.991 展示了 Milstein 的预期优势。步长缩小 16 倍时，EM 的终值误差约缩小 4 倍，Milstein 约缩小 15.6 倍。这是在固定网格下比较精度，并非在相同计算成本下比较速度。

均值精度。路径更准确，不自动意味着每个观测量的偏差都更小。两种 GBM 方法有相同的解析一阶均值偏差，控制后的模拟斜率也接近一阶。直方图和分位数进一步检查了均值无法反映的分布特征。各网格观测到的负终值频率均为零，但 EM 公式仍然允许负更新。

没有精确解时的精度。非仿射模型在三种参考下的强斜率都接近半阶。较粗网格的看涨收益差可以从抽样噪声中分辨出来，较细网格则不能，因此不对完整范围指定弱阶。样本量实验显示，增加路径数使区间宽度近似按 $M^{-1/2}$ 缩小，但三种样本规模仍无法分辨 $N = 64$ 的收益差。

三个问题因此得到不同层次的回答：GBM 的精确解验证、均值偏差的解析解释，以及非仿射模型的参考加密证据。增加路径数不能修复分辨率不足的参考，减小步长也不能单独消除抽样不确定性。上述结论针对本文给定的参数、终值误差指标和网格范围。

可复现性

随附 Python 文件和保存结果记录了随机种子、样本数量和更新公式。样本量实验读取已有配对终值，没有重新运行 SDE 模拟；全样本均值与标准误差已核对，与保存的原实验一致。附录给出核心更新和复现命令。

AI 致谢

本报告使用 OpenAI Codex 辅助解释数学方法、开发和检查 Python 代码、完成数值计算，以及起草和修改报告。AI 也帮助改善了讨论和结果呈现的清晰度。

参考文献

- [1] *Problem Pack: Five Suggested Directions for the ODE IVP Project*, 课程作业文件, Direction 4, 第 6–7 页。
- [2] D. J. Higham. An algorithmic introduction to numerical simulation of stochastic differential equations. *SIAM Review*, 43(3):525–546, 2001. doi:10.1137/S0036144500378302.
- [3] P. E. Kloeden and E. Platen. *Numerical Solution of Stochastic Differential Equations*. Springer, 1992. doi:10.1007/978-3-662-12616-5.

A Python 实现与复现

下面的代码列出核心数学操作。可执行模块还实现了分批计算、控制变量预实验拟合、不确定性估计、诊断、导出和绘图；完整源码随报告提供。

Listing 1: 核心 SDE 更新和共同路径误差统计。

```

1 import numpy as np
2
3 def coarsen(dw_fine, n_coarse):
4     m, n_fine = dw_fine.shape
5     assert n_fine % n_coarse == 0
6     return dw_fine.reshape(m, n_coarse, -1).sum(axis=2)
7
8 def gbm_terminal(dw, s0=100., mu=.05, sigma=.3, T=1.):
9     h = T / dw.shape[1]
10    exact = s0 * np.exp((mu-.5*sigma**2)*T
11                      + sigma*dw.sum(axis=1))
12    em = s0 * np.prod(1 + mu*h + sigma*dw, axis=1)
13    mil = s0 * np.prod(1 + mu*h + sigma*dw
14                      + .5*sigma**2*(dw*dw-h), axis=1)
15    return exact, em, mil
16
17 def log_em_step(x, y, dw1, dw2, h):
18     # 两个右端都使用旧时刻的数值。
19     sigmoid = np.exp(-np.logaddexp(0., -y))
20     g = .1 + .4*sigmoid
21     x_new = x + (.05-.5*g*g)*h + g*dw1
22     y_new = y + 2*(-.2-y)*h + .6*np.hypot(1.,y)*dw2
23     return x_new, y_new
24
25 def mean_ci(values):
26     m = len(values)
27     mean = np.mean(values)
28     half_width = 1.96*np.std(values, ddof=1)/np.sqrt(m)
29     return mean, mean-half_width, mean+half_width
30
31 # 从独立标准正态数生成相关布朗增量:
32 # dw1 = sqrt(h)*z1
33 # dw2 = sqrt(h)*(rho*z1 + sqrt(1-rho**2)*z2)
34 # 强误差: mean_ci(abs(s_coarse-s_reference))
35 # 弱误差: mean_ci(maximum(s_coarse-100,0)
36 #               -maximum(s_reference-100,0))

```

在原项目目录中运行:

```

python -m pip install -r requirements.txt
python run_all.py

# 在不重新模拟的情况下核对已有结果:
python verify.py

```

在本目录中重建补充表格并编译中文报告:

```

python sample_size_study.py
python translate_figures.py
tectonic Coursework_Undergraduate_中文.tex

```

原项目的 results/ 保存机器可读的表格和日志, figures/ 保存矢量 PDF 和 PNG 图。附录代码用于解释核心算法; 完整复现需要两个模拟模块, 而只重建报告表格不会重新模拟路径。