

怎样理解这次随机微分方程大作业？

面向数值 PDE 课程的应用数学本科生
从概率论基础到数值实验与报告解释

配套教学文档

2026 年 9 月

阅读起点。假设你学过微积分、概率论和最基础的欧拉法，但没有金融、随机微积分或随机微分方程基础。本文会先解释“网格”和“离散格式”这两个数值 PDE 术语，再进入本题；不要求你先学完整的金融数学课程。

这份作业的核心。给定一个带随机扰动的连续时间模型，设计离散计算，选择合适的误差指标，并用可复现的证据说明计算结果有多可信。资产价格只是模型背景；主要工作仍然是数值分析。

与现有报告的关系。本文解释 problem pack 第四题和当前本科版报告的数学逻辑。它是一份学习指南，不替代提交报告。文中结果来自已有实验，只复述已经完成的一个样本量实验，不新增大规模计算。

目录

1	先把题目翻译成数值分析问题	3
2	没有金融背景也能读懂的模型词汇	5
3	随机扰动怎样进入时间推进?	6
4	为什么变量变换会多出半个二阶导数?	7
5	三个更新公式分别承担什么角色?	8
6	强误差和弱误差: 先明确你要算准什么	9
7	为什么还要报告路径数和置信区间?	10
8	网格怎样比较: 同一条随机路径是关键	11
9	非仿射模型: 只是多了一个随机变化的系数	12
10	没有精确终值, 怎样验证?	13
11	与数值 PDE 的直接联系: 期望满足一个 PDE	14
12	对照已有数据: 每个结论究竟说明了什么?	15
13	怎样把公式落实到现有代码?	16
14	作为本科大作业, 应怎样组织工作和报告?	17
A	可运行的核心教学代码	18
B	使用方式与材料来源	19

建议读法: 先读第 1-7 节, 理解题意和误差; 再读模型与代码; 最后用第 12 节核对报告中的结论。

1 先把题目翻译成数值分析问题

你在数值 PDE 中可能熟悉这样的流程：先找一个有解析解的例子检查程序，再解决没有解析解的问题；逐渐减小网格间距，观察误差是否按预期下降。这道题沿用同样的思想，但解变成了随机量，误差的定义和测量方法必须随之改变。

从你会的欧拉法开始：网格和离散格式到底是什么？

先只看一个常微分方程

$$u'(t) = f(t, u(t)), \quad u(0) = u_0.$$

选定终点 T 和步数 N ，把时间段 $[0, T]$ 等分为

$$0 = t_0 < t_1 < \cdots < t_N = T, \quad h = t_{n+1} - t_n = T/N.$$

这一串时间点就是**时间网格**； h 是网格步长。网格不是额外的物理对象，只是我们决定在哪些时刻保存近似值。

欧拉法用差商代替导数，并把右端函数在左端点计算：

$$\frac{u_{n+1} - u_n}{h} \approx f(t_n, u_n), \quad u_{n+1} = u_n + hf(t_n, u_n).$$

这条递推公式就是一个**离散格式**：它把连续方程变成计算机可以逐步执行的规则。连续解 $u(t)$ 、网格点 t_n 、近似值 u_n 是三件不同的东西。减小 h 就是**网格加密**；比较不同 h 下的误差，就是**收敛实验**。

如果方程还有空间变量，例如热方程 $u_t = \kappa u_{xx}$ ，就要同时选空间点

$$x_j = j\Delta x$$

和时间点 $t_n = n\Delta t$ 。这时网格是一个点阵；例如中心差分 and 显式欧拉给出

$$u_j^{n+1} = u_j^n + \kappa \frac{\Delta t}{(\Delta x)^2} (u_{j+1}^n - 2u_j^n + u_{j-1}^n).$$

这才是数值 PDE 中常说的空间网格、时间网格和离散格式。本题没有空间变量，也不要求求解这个 PDE；它只有**时间网格**，所以你只需把“每一步如何更新”理解清楚。

对本题而言， $N = 64$ 的网格就是把 $[0, 1]$ 切成 64 个时间段， $h = 1/64$ 。 $N = 8192$ 是更细的时间网格。所谓“参考网格”不是新的真实模型，而是用更小步长得到的数值近似，用来帮助判断粗网格是否已经稳定。随机模型还要在每个时间段生成一个随机增量，因此网格加密同时意味着要生成更多的随机小步。

数值 PDE 中熟悉的概念	本题中的对应问题
有解析解的测试算例	GBM：可以得到同一随机驱动下的精确终值
时间离散格式	Euler-Maruyama (EM) 与 Milstein 更新
误差范数	终值强误差，或某个观测量的弱误差
网格加密实验	步长 $h = T/N$ 逐渐减小
高分辨率参考解	无精确采样公式时使用很细的 EM 网格
数值积分或统计估计	多条独立路径近似期望，并报告标准误差

先读清任务边界。题目首页说明，第四题是 SDE 扩展方向：通常的确定性稳定性、自适应分析，由 GBM 的精确-EM-Milstein 比较、耦合路径的强弱收敛、蒙特卡洛不确定性以及非仿射模型的嵌套网格验证替代。因此，不必为了凑形式另加三个 PDE 格式、CFL 图或自适应算法。GBM 的“精确模拟”是基准，它不具有待测的非零离散误差阶。

第一部分是明确列出的 GBM 检查：

1. 强误差随步长变化：EM 预期半阶，Milstein 预期一阶。
2. 终值均值的弱误差：两者预期一阶，需控制抽样噪声。
3. 终值分布与理论对数正态分布比较。

4. 正值性在原题中标为选做；现有报告已保留这一诊断。

题目第 7 页进一步给出非仿射随机波动率模型，要求使用指定参数及 EM 更新；其后几项以“推荐扩展”列出。当前报告已经选择完成这部分，所以应把它解释清楚：用三层参考检查强差，估计非线性收益差及其区间，并核查生成的噪声与状态。不要把推荐扩展的每一项都改说成全课程统一的硬性要求。

应交付的证据。每个结论都应能回答：比较的是什么，使用了哪些网格和路径数，误差如何计算，不确定性有多大，以及结论在哪个范围内成立。

2 没有金融背景也能读懂的模型词汇

用 S_t 表示时刻 t 的一个正数状态。在金融背景下它叫资产价格；在数值分析中，你可以先把它看成一个随时间随机变化的标量。

符号或术语	在本题中需要的含义
S_0	初值，本实验取 100。
μ : 漂移	模型中平均增长的系数，不表示每条路径都按该速度增长。
σ : 波动率	随机扰动的强度，不是价格本身的方差。
T	观察终点，本实验取 1；可理解为一个时间单位。
$X = \log S$	变量变换，用 $S = e^X$ 保证数学上的正值。
K : 执行价	定义观测函数时使用的阈值，本题取 100。
$\varphi(S) = (S - K)^+$	$\max(S - K, 0)$ ，称为看涨收益。

例如，终值分别为 80、100、120 时， $\varphi(S)$ 分别为 0、0、20。对我们来说，它就是一个非线性测试函数，用于考察数值方法是否正确计算终值分布的某一方面。理解这个函数不需要期权交易知识。

均值和收益期望是两个不同的观测量。假设状态始终为 100，则均值为 100，收益期望为 0。假设状态以各 1/2 的概率为 80 或 120，则均值仍为 100，但收益期望为 10。于是，正确的均值不保证正确的非线性观测量。这和一个 PDE 离散解总质量正确、局部形状却可能不正确的情形相似。

本文只研究题目给定模型下的期望收益。题目没有提供风险中性定价所需的测度说明与贴现设定，所以不用把 $\mathbb{E}[(S_T - 100)^+]$ 叫作已经完成的期权定价。

为什么先研究一个已有精确公式的模型？

它的用途类似你用热方程的已知解验证差分格式：先把“程序错误”和“未知真解”分开。GBM 提供非常强的基准，可以对同一次随机扰动比较精确解和数值解。等这一步通过后，再把同样的实验设计用于没有方便精确解的模型。

这里的精确指网格点转移分布与模型一致，没有时间离散误差；有限精度运算和有限样本估计仍然存在。即使精确抽样，样本均值也不会恰好等于理论均值。

3 随机扰动怎样进入时间推进?

先看普通 Euler 方法。对于 $u' = a(u)$, 一步是

$$u_{n+1} = u_n + a(u_n)h.$$

随机微分方程写成

$$dS_t = a(S_t) dt + b(S_t) dW_t. \quad (1)$$

它的含义来自积分方程:

$$S_t = S_0 + \int_0^t a(S_s) ds + \int_0^t b(S_s) dW_s.$$

第二个积分是随机积分, 不能把 W 当成普通可微函数。这里使用 Itô 约定, 其离散近似在每个时间段用左端点状态作为系数。我们先掌握这一约定及其必要后果, 不展开完整的随机积分理论。

布朗运动: 足以写程序的三个性质

标准布朗运动从 $W_0 = 0$ 出发, 增量满足:

1. 长度为 h 的时间段上, $\Delta W \sim N(0, h)$ 。
2. 不重叠时间段上的增量相互独立。
3. 连续路径通常不可微, 所以不应使用普通导数 $W'(t)$ 做数值推进。

因此生成增量时必须使用

$$\Delta W_n = \sqrt{h} Z_n, \quad Z_n \sim N(0, 1). \quad (2)$$

这里 $N(0, h)$ 的第二个参数是方差; NumPy 的 `normal` 接收的 `scale` 是标准差, 应传入 $\sqrt{h}$ 。

为什么不能用 hZ ? 因为 $\text{Var}(hZ) = h^2$ 。如果用 T/h 个这样的独立增量, 总方差只有 Th , 随网格加密趋于零, 原本需要保留的随机效应会被错误地消掉。用 $\sqrt{h}Z$, 总方差则为 $(T/h)h = T$ 。

于是式 (1) 的最简单离散化为

$$S_{n+1} = S_n + a(S_n)h + b(S_n)\Delta W_n. \quad (3)$$

这就是 EM。形式上像 Euler 多了一个噪声项, 但误差阶不能直接从 ODE 的 Euler 方法搬过来: 随机增量的典型尺度是 $\sqrt{h}$, 不是 h 。

4 为什么变量变换会多出半个二阶导数?

普通微积分中, 若 $X = f(S)$, 你会写 $dX = f'(S)dS$ 。随机情形中还必须保留一个二阶项。理解这一点, 就能理解题目中最容易困惑的 $-\sigma^2/2$ 。

从 Taylor 展开看需要保留什么

形式上展开一步:

$$\Delta f \approx f'(S)\Delta S + \frac{1}{2}f''(S)(\Delta S)^2.$$

由于 $\Delta S \approx ah + b\Delta W$, 而 $(\Delta W)^2$ 的期望为 h , 二阶项累计后不会消失。更具体地, 对独立正态增量,

$$\mathbb{E} \sum_{n=0}^{N-1} (\Delta W_n)^2 = Nh = T, \quad \text{Var} \left(\sum_{n=0}^{N-1} (\Delta W_n)^2 \right) = 2Nh^2 = 2Th \rightarrow 0.$$

这说明平方增量之和逼近 T 。这不表示每一步都有 $(\Delta W)^2 = h$; 单步平方仍是随机量。以上是 Itô 修正的直观依据, 不是对一般 Itô 公式的完整证明。

在合适的光滑性条件下, 正确公式为

$$df(S_t) = (af' + \frac{1}{2}b^2 f'')(S_t) dt + b(S_t)f'(S_t) dW_t. \quad (4)$$

应用于 GBM

题目模型为 $dS = \mu S dt + \sigma S dW$ 。取 $f(S) = \log S$, 则 $f' = 1/S$, $f'' = -1/S^2$ 。代入式 (4):

$$dX = (\mu - \frac{1}{2}\sigma^2)dt + \sigma dW.$$

两项系数均为常数, 积分后再取指数得到

$$S_T = S_0 \exp\{(\mu - \frac{1}{2}\sigma^2)T + \sigma W_T\}. \quad (5)$$

由正态变量的公式 $\mathbb{E}e^{cZ} = e^{c^2/2}$ (可通过配方积分验证),

$$\mathbb{E}S_T = S_0 e^{\mu T}, \quad \text{Var}(S_T) = S_0^2 e^{2\mu T} (e^{\sigma^2 T} - 1).$$

若漏掉 $-\sigma^2/2$, 计算出的均值就多出 $e^{\sigma^2 T/2}$, 已经改变了模型。所谓对数正态分布, 正是 $\log S_T$ 服从正态分布。

5 三个更新公式分别承担什么角色？

对同一个增量 ΔW_n ，题目比较以下三种计算。

$$S_{n+1}^{\text{exact}} = S_n^{\text{exact}} e^{(\mu - \sigma^2/2)h + \sigma \Delta W_n}, \quad (6)$$

$$S_{n+1}^E = S_n^E (1 + \mu h + \sigma \Delta W_n), \quad (7)$$

$$S_{n+1}^M = S_n^M [1 + \mu h + \sigma \Delta W_n + \frac{1}{2} \sigma^2 ((\Delta W_n)^2 - h)]. \quad (8)$$

式 (6) 是基准，式 (7) 是价格变量上的 EM，式 (8) 是价格变量上的 Milstein。

Milstein 的额外项从哪里来？

把精确乘子展开，按 ΔW 的尺度保留到 h ：

$$e^{(\mu - \sigma^2/2)h + \sigma \Delta W} \approx 1 + \mu h + \sigma \Delta W + \frac{1}{2} \sigma^2 ((\Delta W)^2 - h).$$

普通 EM 丢掉了最后一个随机修正。它的均值是零，却会影响每一条路径的误差。Milstein 保留它，因此能提高精度。这是针对 GBM 的直观推导；一般标量 SDE 的对应系数为 $\frac{1}{2}b(S)b'(S)$ ，其完整收敛证明需要另外的条件和理论。

为什么不用对数变量比较三个方法？ 因为 GBM 的 X 方程系数是常数，EM 对它的网格转移已经精确；加性噪声的 Milstein 修正又是零。这样两种方法会退化为相同的精确更新，无法展示半阶和一阶的差别。所以题目明确要求 GBM 的收敛比较在 S 上进行。

正值性与稳定性不要混为一谈

精确指数更新为正；EM 乘子可能为负。Milstein 是否为正，要看参数和步长。当前参数 $\mu = 0.05, \sigma = 0.30$ 下，配方得到

$$1 + \mu h + \sigma \Delta W + \frac{1}{2} \sigma^2 ((\Delta W)^2 - h) = \frac{1}{2} \sigma^2 (\Delta W + 1/\sigma)^2 + \frac{1}{2} + 0.005h > 0.$$

这是当前参数的结论，不是对所有 GBM 参数的无条件结论。也不能把“没有负值”或“没有爆炸”当作“误差足够小”。本题无须另做确定性 CFL 分析，但仍应检查有限性、正值性和加密行为。

6 强误差和弱误差：先明确你要算准什么

设 S_T 是精确终值， S_T^h 是数值终值。两者都随机，因此“误差”不再只有一个自然定义。
强误差问的是：同一种随机扰动下，终值能否算准？

$$e_s(h) = \mathbb{E}|S_T^h - S_T|. \quad (9)$$

先在每条对应路径上取绝对误差，再平均。这是终值 L^1 误差，不是时间区间上的最大误差，也不是均方误差；不同定义不能混用。若 $e_s(h) \approx Ch^p$ ，就称观察到了 p 阶的规律。

弱误差问的是：我关心的统计量能否算准？

$$e_w(h) = |\mathbb{E}\varphi(S_T^h) - \mathbb{E}\varphi(S_T)|. \quad (10)$$

GBM 部分使用 $\varphi(s) = s$ ，考察均值。非仿射部分使用 $\varphi(s) = (s - 100)^+$ ，考察非线性收益。

假设三条路径的终值误差是 $1, -1, 0$ 。则平均绝对误差为 $2/3$ ，带符号的平均误差却为 0 。抵消可以使均值比单条路径更准确。因此，“Milstein 路径误差更小”并不自动推出“它的均值偏差也比 EM 小”。

怎样从加密结果理解阶数？

若 $e(h) \approx Ch^p$ ，则

$$\frac{e(h)}{e(h/2)} \approx 2^p, \quad p \approx \frac{\log(e(h)/e(h/2))}{\log 2}.$$

半阶意味着步长减半时误差乘 $1/\sqrt{2}$ ；一阶意味着乘 $1/2$ 。多层网格的 $\log$ - $\log$ 拟合是在估计 $\log e = \log C + p \log h$ 的斜率。

实验斜率不是理论证明。需要说明拟合了哪些网格。粗网格可能尚未进入渐近区，极细网格则可能受参考误差或抽样噪声影响。各网格使用共同路径时，误差点也相互相关；不要直接套用独立观测回归的置信区间。

特别地，弱偏差的估计可能正也可能负。先取绝对值再在对数图上拟合，可能把纯粹的噪声画成一条“收敛曲线”。应先检查带符号估计及其不确定性。

7 为什么还要报告路径数和置信区间?

一次计算得到一个随机终值, 重复 M 条独立路径才能估计期望。这里有两种完全不同的分辨率: 时间步数 N 决定 $h = T/N$, 路径数 M 决定统计精度。

设每条路径上计算的量为 D_i 。它可以是强误差中的绝对差, 也可以是弱误差中的带符号收益差。定义

$$\bar{D} = \frac{1}{M} \sum_{i=1}^M D_i, \quad s_D^2 = \frac{1}{M-1} \sum_{i=1}^M (D_i - \bar{D})^2, \quad \text{SE}(\bar{D}) = \frac{s_D}{\sqrt{M}}.$$

有限方差与大样本条件下, 近似逐点 95% 置信区间为

$$\bar{D} \pm 1.96 \frac{s_D}{\sqrt{M}}. \quad (11)$$

样本标准差 s_D 描述路径间的分散程度, 标准误差 SE 描述平均值估计的不确定性。95% 指在重复抽样中构造的区间约有该覆盖率, 不是保证这一次区间必然含有真值; 多个步长的逐点区间也不是联合 95% 保证。

把误差分成三部分

设参考步长为 r , $b_{h,r} = \mathbb{E}[\varphi(S_T^h) - \varphi(S_T^r)]$, 真实目标 $Q = \mathbb{E}\varphi(S_T)$ 。若 $\hat{b}$ 是配对样本平均, 则

$$\hat{b} - (\mathbb{E}\varphi(S_T^h) - Q) = \underbrace{\hat{b} - b_{h,r}}_{\text{抽样误差}} + \underbrace{Q - \mathbb{E}\varphi(S_T^r)}_{\text{参考的离散偏差}}. \quad (12)$$

区间 (11) 只衡量第一项, 不覆盖第二项。GBM 使用精确参考时第二项为零; 非仿射模型则必须检查参考加密。

区间跨零意味着什么? 这批数据还不能可靠地区分正偏差、负偏差和零。它不证明真偏差为零, 也不自动证明方法失败。题目明确提醒: 偏差与抽样不确定性相当时, 不应声称测出了弱阶。

控制变量的最低限度理解。 若 $\mathbb{E}C = 0$, 对预先固定的 β , $\mathbb{E}(D - \beta C) = \mathbb{E}D$ 。若 C 与 D 相关, 适当相减可减小方差。现有 GBM 程序用独立预实验拟合系数, 再用于正式样本; 它减少噪声, 不改变离散格式或真实偏差。初读时无需先掌握五个控制量的全部公式。

8 网格怎样比较：同一条随机路径是关键

在确定性 PDE 中，换网格不代表换一个初边值问题。同样，在 SDE 强误差实验中，换步长不能顺便换一套随机驱动。

先生成最细网格增量 $\delta W_0, \dots, \delta W_{N_f-1}$ ，再把相邻 r 个相加：

$$\Delta W_n^h = \sum_{j=nr}^{(n+1)r-1} \delta W_j, \quad h = rT/N_f. \quad (13)$$

例如最细网格 8 步、粗网格 4 步，每两个细增量相加。和的方差为 $2(T/8) = T/4$ ，正好是粗步长，而且时间端点上对应同一个布朗运动。4 步与 8 步的总增量完全相同。

```
def coarsen(dw_fine, n_coarse):
    m, n_fine = dw_fine.shape
    return dw_fine.reshape(m, n_coarse,
                           n_fine//n_coarse).sum(axis=2)
```

这里矩阵的每行是一条路径，每列是一个时间增量。使用此函数前必须保证整除，随附源码包含这个检查。

仅仅设相同随机种子并不等于完成耦合。不同网格消耗随机数的数量和顺序可能不同；应明确用式 (13) 聚合，不能凭种子相同就认定路径相同。

如果精确值和数值值来自独立驱动，即使数值法趋于精确，平均绝对差仍会趋于两个独立终值之间的差，而不是零。这样检验的是随机样本差异，不是数值误差。

配对也能帮助弱误差估计

设 $A = \varphi(S_T^h)$ ， $B = \varphi(S_T^r)$ 。弱误差的目标只涉及各自的分布，理论上不强制配对，但

$$\text{Var}(A - B) = \text{Var}(A) + \text{Var}(B) - 2 \text{Cov}(A, B).$$

共同随机数通常使相近网格结果高度正相关，因而减少差值的方差。这解释了为什么应直接计算每对差 $D_i = A_i - B_i$ 的标准误差，而不是把两个独立均值的误差公式套过来。

注意两种关系同时成立：**同一行不同网格要相关，不同行的模拟路径要独立。**前者保证公平比较，后者支持标准误差公式。

9 非仿射模型：只是多了一个随机变化的系数

GBM 的扰动强度 σ 不变。第二个模型让它由额外状态 Y_t 决定：

$$dX_t = (\mu - \frac{1}{2}g(Y_t)^2)dt + g(Y_t)dW_t^{(1)}, \quad (14)$$

$$dY_t = \kappa(\theta - Y_t)dt + \xi\sqrt{1 + Y_t^2}dW_t^{(2)}, \quad (15)$$

$$g(y) = 0.10 + \frac{0.40}{1 + e^{-y}}, \quad S_t = e^{X_t}. \quad (16)$$

这里 Y 是调节噪声强度的辅助状态，可以取负值；真正的波动率 $g(Y)$ 始终在 0.10 与 0.50 之间。 $\kappa(\theta - Y)$ 会把 Y 拉回 θ 附近； $\xi\sqrt{1 + Y^2}$ 表示 Y 自身的扰动强度也依赖状态。名称“非仿射”不需要专门的金融背景：这道题需要知道的实际后果是，不能像 GBM 一样直接套用方便的精确转移公式。

指定参数为 $S_0 = 100, Y_0 = 0, \mu = 0.05, \kappa = 2, \theta = -0.2, \xi = 0.6, \rho = -0.7, T = 1$ 。它们是本题的可复现基准，不需要另做市场数据拟合。

两个噪声为什么有关联？

由独立标准正态 Z_1, Z_2 生成

$$\Delta W^{(1)} = \sqrt{h}Z_1, \quad \Delta W^{(2)} = \sqrt{h}(\rho Z_1 + \sqrt{1 - \rho^2}Z_2).$$

直接计算可得，两者方差都是 h ，协方差为 ρh ，所以相关系数为 ρ 。这只是概率论里的线性组合，不要求理解尖括号记号 $d\langle W^{(1)}, W^{(2)} \rangle = \rho dt$ 的完整定义。负相关表示同一步两个驱动倾向于反向变化，不是说两个状态始终反向运动。

实现的一个关键细节

两条 EM 更新的系数都必须使用旧值 Y_n ：

$$X_{n+1} = X_n + (\mu - \frac{1}{2}g(Y_n)^2)h + g(Y_n)\Delta W_n^{(1)}, \quad (17)$$

$$Y_{n+1} = Y_n + \kappa(\theta - Y_n)h + \xi\sqrt{1 + Y_n^2}\Delta W_n^{(2)}. \quad (18)$$

像显式耦合 PDE 系统一样，应先算两个新值，再统一赋值。先改写 Y 再用于 X ，就改变了算法。两维噪声的 Milstein 也不能直接照抄 GBM 的标量修正；本题在这里使用 EM 即可。

10 没有精确终值，怎样验证？

这一步最接近你在数值 PDE 中做的网格加密实验。现有报告使用粗网格 $N = 8, 16, 32, 64, 128, 256$ ，参考网格 $N_r = 2048, 4096, 8192$ 。所有网格由 8192 步的同一对细增量聚合得到。

先计算 $\mathbb{E}|S_T^h - S_T^r|$ 的样本估计和区间。但名称应是“相对于数值参考的强差”，不能直接叫作已知的精确误差。若 S_T^* 是未知精确终值，反三角不等式给出

$$|\mathbb{E}|S_T^h - S_T^*| - \mathbb{E}|S_T^h - S_T^r|| \leq \mathbb{E}|S_T^r - S_T^*|.$$

右端未知，所以需要更细的参考检查答案是否改变。已有结果中，同一个 $N = 8, 16, 32, 64$ 拟合窗口，在三种参考下的斜率分别为 0.496、0.493、0.491，支持该窗口内半阶趋势对参考选择较稳定的判断。

参考 2048 与 4096 步之间的平均绝对差为 0.05679，4096 与 8192 步之间为 0.04016，后者约为前者的 0.707 倍。这与半阶缩放相容。它仍不是精确误差的认证上界，也没有题目规定的“低于 10% 即通过”的通用阈值。

为什么非仿射模型的均值反而太容易通过？

在一步开始时， S_n 与 $g_n = g(Y_n)$ 已知，下一步增量仍服从 $N(0, h)$ 。因此

$$\begin{aligned} \mathbb{E}[S_{n+1} \mid \text{当前信息}] &= S_n e^{(\mu - g_n^2/2)h} \mathbb{E}[e^{g_n \Delta W_n^{(1)}} \mid \text{当前信息}] \\ &= S_n e^{(\mu - g_n^2/2)h} e^{g_n^2 h/2} = S_n e^{\mu h}. \end{aligned}$$

反复取期望得到 $\mathbb{E}S_N = S_0 e^{\mu T}$ ，与连续模型相同（这里有界的 g 保证所需的可积性）。这个等式对所有步长成立，不受两个驱动在同一步的相关性影响，因为使用的是已知的旧系数。

所以均值很适合检查实现，但其离散偏差恒为零，无法用于测量此方案的非零弱阶。看涨收益没有这种自动保持性质，因而能暴露分布差异。不过它在 $S = 100$ 处不光滑，不能直接、不加说明地套用光滑观测函数的弱阶结论。

11 与数值 PDE 的直接联系：期望满足一个 PDE

这一节帮助你把新任务放回熟悉的知识体系，不是额外要求实现 PDE 求解器。本题的未知 S_t 是有限维随机过程；它本身不是一个带空间变量的随机 PDE。

定义

$$u(t, s) = \mathbb{E}[\varphi(S_T) \mid S_t = s].$$

它表示“从时刻 t 、状态 s 出发，到终点的平均观测值”。对于 $dS = a(S)dt + b(S)dW$ ，在能合法进行以下展开的光滑条件下，利用一步条件期望与 Taylor 展开：

$$\begin{aligned} u(t, s) &= \mathbb{E}[u(t+h, S_{t+h}) \mid S_t = s], \\ 0 &\approx hu_t + ha(s)u_s + \frac{1}{2}hb(s)^2u_{ss}. \end{aligned}$$

这里用到了 $\mathbb{E}\Delta S \approx a(s)h$ 、 $\mathbb{E}(\Delta S)^2 \approx b(s)^2h$ 。除以 h ，得到后向方程

$$u_t + a(s)u_s + \frac{1}{2}b(s)^2u_{ss} = 0, \quad u(T, s) = \varphi(s). \quad (19)$$

对 GBM，它是

$$u_t + \mu su_s + \frac{1}{2}\sigma^2 s^2 u_{ss} = 0.$$

这是带终值条件的抛物型方程；令 $\tau = T - t$ ，便转成从 $\tau = 0$ 开始的演化问题。系数在 $s > 0$ 上给出扩散项，在 $s = 0$ 处退化。若实际做 PDE 计算，还需处理无界状态域的截断及边界条件，本题没有要求完成这些额外工作。

同一目标的两条数值路线。有限差分或有限元在状态空间上近似 u ；蒙特卡洛路线模拟很多轨道，再平均 $\varphi(S_T)$ 。两者都在求 $u(0, S_0)$ 。这里采用后者，所以误差预算除了时间离散，还多了一项 $M^{-1/2}$ 规模的抽样不确定性。

取 $\varphi(s) = s$ 时， $u(t, s) = se^{\mu(T-t)}$ 满足上述方程： $u_{ss} = 0$ ，扩散项消失。这从 PDE 角度解释了 GBM 均值为什么不依赖 σ ，也提醒我们：只测均值可能看不到扩散部分的误差。非光滑收益的终值条件需要更谨慎地理解，以上光滑展开不是其边界处的完整正则性证明。

12 对照已有数据：每个结论究竟说明了什么？

结论一：Milstein 的路径精度更高。GBM 的强斜率为 EM 0.500、Milstein 0.991。步数从 64 增至 1024，步长缩小 16 倍；EM 误差从 0.66641 降至 0.16658，约缩小 4 倍；Milstein 从 0.02391 降至 0.00153，约缩小 15.6 倍。这正是半阶与一阶最直观的区别。它是固定网格下的精度比较，不等于相同计算成本下的速度排名。

结论二：两种 GBM 方法的均值偏差相同。两种乘子的条件均值都是 $1 + \mu h$ ，所以

$$\mathbb{E}S_N^E = \mathbb{E}S_N^M = S_0(1 + \mu h)^{T/h}.$$

用 $\log(1 + \mu h) = \mu h - \mu^2 h^2/2 + O(h^3)$ 展开：

$$\mathbb{E}S_N - S_0 e^{\mu T} = -\frac{1}{2} S_0 e^{\mu T} \mu^2 T h + O(h^2).$$

这在当前 $\mu \neq 0$ 参数下解释了一阶均值偏差。控制后测得斜率约为 0.999 与 1.000。若 $\mu = 0$ ，这一均值测试会退化为零偏差；所以观测量和参数的选择都重要。

结论三：非仿射细网格弱差尚未分辨。在 $N = 8, 16, 32$ ，收益差区间不跨零；在 $N = 64, 128, 256$ ，区间跨零。不能为了得到一条漂亮直线就强行拟合整个区间的弱阶。即使某些区间不跨零，也仍需检查网格范围和参考敏感性，不能只凭“显著”就断定进入了渐近区。

表 1: 固定网格 $N = 64$ 与参考 $N_{\text{ref}} = 8192$ ；使用保存样本的嵌套前缀。

路径数 M	带符号收益差	标准误差	95% 区间
10,000	0.009045	0.005149	[-0.001048, 0.019137]
40,000	0.004942	0.002592	[-0.000139, 0.010022]
100,000	0.001722	0.001633	[-0.001479, 0.004923]

这一个样本量实验固定两层网格，只改变用于平均的路径数。路径数从 1 万变成 4 万，标准误差从 0.005149 降至 0.002592，约减半；变成 10 万后为 0.001633。但三组区间仍跨零。

应怎样解释？增加样本确实提高了精度，但不保证这些规模足以辨认当前偏差。三组使用保存顺序的嵌套子集，彼此相关。由于 h 和参考都没变，点估计下降不是时间离散偏差下降；10 万条路径的估计也不是真值。

13 怎样把公式落实到现有代码？

随附 `teaching_core.py` 是短小的教学实现，便于逐行阅读。它使用形状 (M, N) 的数组：行是路径，列是时间。原项目 `nonaffine.py` 则采用时间在前的布局，不能不改轴号就复制其 `reshape` 操作。

GBM：一个细网格服务所有粗网格

概念上的调用流程为：

```
rng = np.random.default_rng(seed)
fine = rng.normal(0., np.sqrt(T/n_fine), (M, n_fine))
for n in grid_sizes:
    dw = coarsen(fine, n)
    exact, em, mil = gbm_terminal(dw, T=T)
    strong_em = estimate(np.abs(em-exact))
    weak_mean_em = estimate(em-exact)
```

这里故意区分强差与均值弱差；如果调用针对看涨收益的函数，就改变了 GBM 本部分的测试目标。精确终值只需要同一行的增量总和。EM 和 Milstein 的终值可以写成乘子连乘，原项目的向量化实现与逐步更新相同。

非仿射：两个驱动都要聚合

生成两组独立标准正态数，转换为相关细增量。对每个网格，分别聚合两个驱动，再调用 `nonaffine_terminal`。先保存所有网格的终值，随后用相同路径序号的粗终值与参考终值计算差。

原项目中的位置	先阅读什么
<code>gbm.py: simulate_batch</code>	细增量聚合、精确终值、两种乘子；控制变量可稍后读。
<code>gbm.py: fit_controls</code>	独立预实验如何拟合控制系数。
<code>nonaffine.py: em_terminal</code>	如何聚合两个驱动。
<code>nonaffine.py: _em_kernel</code>	为什么保存旧 Y ，如何更新 X, Y 。
<code>verify.py</code>	公式、耦合和已有结果的一致性检查。
<code>undergraduate_revision/</code>	当前报告、样本量脚本及完整结果。

正式程序分批处理路径以节省内存。分批是计算组织方式，不应改变理论算法。复现需记录随机种子、批大小、路径数、网格和软件环境，不能只保存最后一张图。

14 作为本科大作业，应怎样组织工作和报告？

1. **先写目标和指标。**说明 GBM 用来验证方法，非仿射模型用来检验无精确解时的验证策略；明确定义终值强误差与观测量弱误差。
2. **先核对更新，再跑大样本。**检查 $\sqrt{h}$ 、Milstein 的 $-h$ 项、噪声相关系数以及旧状态同步更新。精确 GBM 终值在各层粗化后应一致。
3. **设计耦合网格。**确定一组嵌套网格及统一最细驱动。固定参数和种子，避免运行后只挑选支持预期结论的数据。
4. **完成 GBM 三类证据。**强误差与斜率、均值偏差与区间、直方图与分位数。样本均值和理论均值接近只是其中一项检查。
5. **完成选定的非仿射扩展。**重复参考加密，报告经验强趋势，保留弱差的符号和区间。明确参考也有偏差。
6. **解释局限。**说明未分辨的弱差、拟合窗口以及负值诊断的范围。不要把数据支持不到的结论写成定理。

报告正文的三个中心问题

可以直接沿用当前本科版：同一条路径谁更准确？路径更准确是否意味着均值更准确？没有精确解时怎样判断结果可信？每个问题依次给出定义、方法、证据和解释。这样公式与图表都服务于具体问题，读者不会只看到一串技术名词。

哪些知识要会，哪些可以暂缓？

需要会解释布朗增量的方差、Itô 修正的来源、三个 GBM 更新、条件期望、强弱差别、配对和置信区间。需要知道强阶结论有适用条件，但不必把完整 SDE 存在唯一性证明、一般 Milstein 理论或多维迭代随机积分加入本科报告。后向 PDE 是帮助理解期望的桥梁，也无需另写一套 PDE 实验。

最后用五个问题检查自己是否理解

1. 把 $\sqrt{h}Z$ 写成 hZ ，为什么加密后模型会变？
2. 两种方法的均值都正确，能否说明路径和分布都正确？
3. 强误差实验中独立生成粗细路径，为什么不公平？
4. 区间跨零，为什么既不能说“误差为零”，也不能强报弱阶？
5. 把路径数增加十倍与把时间步数增加十倍，分别改变什么？

答案依次对应第 3、6、8、7 和 7 节。能用自己的话回答这些问题，比记住某个拟合斜率的三位小数更能体现对这次作业的理解。

A 可运行的核心教学代码

下面的代码没有完整报告生成、控制变量拟合和正式实验的批处理，目的是把数学公式对应到实现。文件末尾的检查只使用少量固定增量，检验计算逻辑，不产生新的收敛实验数据，也不覆盖已有结果。

```
import numpy as np

def coarsen(dw_fine, n_coarse):
    """Sum neighbouring increments; retain the same Brownian realization."""
    m, n_fine = dw_fine.shape
    if n_coarse < 1 or n_fine % n_coarse:
        raise ValueError("n_coarse must divide the fine-grid size")
    return dw_fine.reshape(m, n_coarse, n_fine // n_coarse).sum(axis=2)

def gbm_terminal(dw, s0=100., mu=.05, sigma=.3, T=1.):
    h = T / dw.shape[1]
    exact = s0 * np.exp((mu - .5*sigma**2)*T + sigma*dw.sum(axis=1))
    multiplier = 1 + mu*h + sigma*dw
    em = s0 * np.prod(multiplier, axis=1)
    mil = s0 * np.prod(multiplier + .5*sigma**2*(dw**2-h), axis=1)
    return exact, em, mil

def correlated_increments(z1, z2, h, rho=-.7):
    """Inputs must be independent arrays of standard normal observations."""
    return np.sqrt(h)*z1, np.sqrt(h)*(rho*z1 + np.sqrt(1-rho**2)*z2)

def nonaffine_terminal(dw1, dw2, T=1.):
    if dw1.shape != dw2.shape:
        raise ValueError("The two increment arrays must have the same shape")
    m, n = dw1.shape
    h = T/n
    x, y = np.full(m, np.log(100.)), np.zeros(m)
    for k in range(n):
        sigmoid = np.exp(-np.logaddexp(0., -y))
        g = .1 + .4*sigmoid
        x_new = x + (.05-.5*g*g)*h + g*dw1[:, k]
        y_new = y + 2*(-.2-y)*h + .6*np.hypot(1., y)*dw2[:, k]
        x, y = x_new, y_new
    return np.exp(x)

def estimate(values):
    """Approximate pointwise 95% CI for the mean of independent paths."""
    values = np.asarray(values)
    if values.ndim != 1 or len(values) < 2:
        raise ValueError("Need at least two path observations")
    mean = float(values.mean())
    se = float(values.std(ddof=1) / np.sqrt(len(values)))
    return dict(mean=mean, se=se, lower=mean-1.96*se, upper=mean+1.96*se)

def error_summaries(coarse, reference, strike=100.):
    strong = estimate(np.abs(coarse-reference))
    payoff_difference = np.maximum(coarse-strike, 0)-np.maximum(reference-strike, 0)
    weak = estimate(payoff_difference)
    return strong, weak
```

B 使用方式与材料来源

在本目录中运行

```
python3 teaching_core.py
tectonic --keep-logs 任务理解与教学指南.tex
```

第一个命令执行少量固定输入的实现检查；第二个编译本指南。Python 依赖 NumPy，中文排版依赖 Noto CJK 字体与 Tectonic。主报告、原始正式实验和教学代码的角色不同：主报告给结论，原程序产生正式证据，教学代码解释核心操作。

如何与主报告配合阅读

先读本指南的误差与耦合部分，再读本科版报告第 4–6 节。遇到一个斜率时，确认它是强误差还是弱误差、对什么参考计算、在哪个网格窗口拟合。遇到一个区间时，确认它针对什么随机变量的均值，以及是否含有参考离散偏差。

已完成的样本量实验位于本科版报告第 11 页；本指南仅解释它，没有另外增加模型、网格、随机种子或实验。理论阐释中的三点离散分布例子属于数学例子，不是额外的数值实验。

材料来源与说明

任务要求依据项目内 `source/problem_pack.pdf` 第 1、6–7 页。数据依据当前 `undergraduate_revision/` 中的本科版报告及 `results/`，实现对应原项目 `gbm.py`、`nonaffine.py` 和 `verify.py`。本文的 Itô 与后向 PDE 推导是面向初学者的解释，已区分直观展开和需要额外假设的完整证明。

本文由 OpenAI Codex 辅助编写、核对代码和排版，作为课程作业的配套学习材料。它不对具体评分结果作保证，也不替代课程正式说明。